INSTITUT ZA MATEMATIKU I INFORMATIKU
PRIRODNO-MATEMATIČKI FAKULTET UNIVERZITET U KRAGUJEVCU

PREDSTAVLJANJE I ANALIZA SKUPA PODATAKA

Industrial Fault Detection Dataset”

Studenti:

Aleksandar Mladenović 68/2022

Đorđe Rajčić 84/2022

Mentor:

Branko Arsić

Kragujevac, decembar 2025.

Sadržaj

Uvod 4
Opis problema i motivacija 5
Učitavanje neophodnih biblioteka 5
Učitavanje seta podataka 7
Eksplorativna analiza podataka (EDA) 10
Osnovne informacije o datasetu 10
Analiza ciljne varijable (Fault_Type) 13
Generisanje histograma osnovnih senzora 15
Boxplotovi senzora u odnosu na Fault_Type 16
Deskriptivna statistika po grupama 20
Analiza korelacije između osnovnih senzorskih promenljivih 23
Vizuelna analiza distribucija po tipovima kvara 26
Provera fizički nelogičnih i nemogućih vrednosti 31
Analiza FFT karakteristika (Temperature, Vibration, Pressure) 32
Preprocesiranje podataka 38
Feature Engineering 38
Obrada Nedostajućih Vrednosti: Strategije i Praćenje 40
Identifikacija Numeričkih Kolona i Provera Near-Zero Variance: Smanjenje Šuma 40
Podela na Trening i Test skup 40
Skaliranje Feature-a: Normalizacija za Modelsku Stabilnost 42
Uklanjanje Visoko Korelisanih Feature-a 42
Balansiranje klasa koristeći SMOTE: obrada neravnotežnih podataka 43
Izgradnja i treniranje modela 46
Evaluacija modela 52
Generisanje predikcija 52
Evaluacija Random Forest modela 53
Evaluacija multinomijalne logističke regresije 53
Evaluacija neuronske mreže (MLP) 54
Evaluacija XGBoost modela 55
Poređenje modela 56
ROC i AUC analiza 57

Važnost obeležja (Random Forest) 58
Zaključak evaluacije 59
Čuvavanje modela i rezultata 59
Kreiranje direktorijuma i čuvanje modela 59
Struktura i čuvanje rezultata evaluacije 59
Kreiranje tekstualnog izveštaja 60
Zaključak 62

Uvod

Industrijsko okruženje predstavlja jedan od najzahtevnijih sistema za nadzor, jer brojni procesi moraju da rade pouzdano, precizno i bez zastoja. Svaki kvar u proizvodnoj liniji može dovesti do značajnih finansijskih gubitaka, smanjenja kvaliteta proizvoda ili potpunog prekida proizvodnje. Zato je pravovremeno otkrivanje grešaka u mašinama i opremi od ključnog značaja za svaku fabriku, bez obzira na veličinu ili vrstu industrije. Blagovremena identifikacija anomalija omogućava inženjerima da reaguju pre nego što kvar eskalira, čime se smanjuju troškovi održavanja, produžava životni vek opreme i povećava ukupna efikasnost proizvodnog sistema. Tradicionalne metode nadzora su se uglavnom oslanjale na periodične vizuelne inspekcije i iskustvo radnika, što je često nedovoljno za otkrivanje kompleksnih ili skrivenih problema u ranim fazama. Ovakvi pristupi umeju da budu spori, subjektivni i ograničeni ljudskim faktorom. Razvojem savremenih digitalnih tehnologija i dostupnošću velikih količina podataka, otkrivanje industrijskih kvarova prelazi na naprednije, automatizovane metode. Analitički modeli i algoritmi mašinskog učenja danas mogu da obrade veliki broj senzorskih signala, identifikuju obrasce koji nisu vidljivi ljudskom oku i sa visokim stepenom tačnosti predvide potencijalne kvarove. Na taj način, industrija prelazi sa reaktivnog na proaktivan pristup održavanju. U okviru ovog rada koristi se skup podataka sa senzora industrijske opreme, koji sadrži informacije o normalnom i anomalnom radu sistema. Cilj je da se na osnovu dostupnih parametara izgradi model koji može da prepozna odstupanja i klasifikuje potencijalne greške. Ovakav pristup nalazi široku primenu u sistemima prediktivnog održavanja, gde se kvarovi otkrivaju pre nego što prouzrokuju veće probleme. Za analizu i obradu podataka korišćen je R, zahvaljujući njegovoj bogatoj kolekciji biblioteka namenjenih statističkom modeliranju, manipulaciji podacima i vizuelizaciji rezultata. R se posebno ističe u zadacima klasifikacije. Pored toga, njegova mogućnost jasnog predstavljanja nalaza kroz grafikone i tabele olakšava interpretaciju rezultata i donošenje zaključaka tokom analize.

Opis problema i motivacija

Iz ugla nauke o podacima, problem detekcije industrijskih kvarova predstavlja zadatak klasifikacije, gde se na osnovu poznatih karakteristika signala (kao što su temperatura, vibracije, pritisak, protok, struja i sl.) pokušava proceniti tip kvara. Cilj je izgraditi model koji može naučiti obrasce i odnose između tih karakteristika i tipa kvara, a zatim ih koristiti za predviđanje kvarova u novim, nepoznatim signalima. U ovom istraživanju koristimo javno dostupan Industrial Fault Detection Dataset koji sadrži podatke merenja sa senzora u industrijskim sistemima. Skup obuhvata atribute koji opisuju različite karakteristike signala, poput osnovnih senzora i FFT karakteristika.

Zadatak projekta je razviti model koji precizno predviđa tip kvara (Fault_Type) na osnovu senzorskih karakteristika. Glavni izazov je konstruisanje robusnog i prediktivnog modela s obzirom na složenost podataka:

- visoka dimenzionalnost zahteva efikasan izbor karakteristika da bi se izbeglo prekomerno prilagođavanje
- mešoviti tipovi podataka zahtevaju pažljivo kodiranje i
- nebalansiranost klasa zahteva balansiranje.

Cilj ovog projekta je uporediti različite modele mašinskog učenja kako bi se identifikovao onaj koji najtačnije detektuje kvarove. Evaluacijom performansi modela analizira se njihova sposobnost da uhvate odnose između karakteristika signala i tipa kvara. Na taj način dolazi se do optimalnog pristupa za pouzdanu detekciju industrijskih kvarova.

Učitavanje neophodnih biblioteka

Na početku se inicijalizuju neophodni paketi u R okruženju kako bi se omogućila efikasna obrada podataka, analiza, modelovanje i evaluacija. Biblioteke su odabrane sa fokusom na minimalizam i performanse, uz izbegavanje nepotrebnih zavisnosti.

```
library(tidyverse)      # Uključuje dplyr, ggplot2, readr, itd.

## ── Attaching core tidyverse packages ──────────────────────── tidyverse 2.
0.0 ──
## ✓ dplyr     1.1.4     ✓ readr     2.1.6
## ✓ forcats   1.0.1     ✓ stringr   1.6.0
## ✓ ggplot2   4.0.1     ✓ tibble    3.3.0
## ✓ lubridate 1.9.4     ✓ tidyr     1.3.1
## ✓ purrr     1.2.0
## ── Conflicts ────────────────────────────────────────── tidyverse_conflict
s() ──
## ✗ dplyr::filter() masks stats::filter()
## ✗ dplyr::lag()    masks stats::lag()
## ℹ Use the conflicted package (<http://conflicted.r-lib.org/>) to force all
conflicts to become errors
```

```r
library(caret)          # Za treniranje i evaluaciju modela
```

```
## Loading required package: lattice
##
## Attaching package: 'caret'
##
## The following object is masked from 'package:purrr':
##
##     lift
```

```r
library(pROC)           # Za ROC i AUC metrike
```

```
## Type 'citation("pROC")' for a citation.
##
## Attaching package: 'pROC'
##
## The following objects are masked from 'package:stats':
##
##     cov, smooth, var
```

```r
library(nnet)           # Za multinomijalnu logističku regresiju
library(patchwork)      # Za kombinovanje ggplot grafikona
library(recipes)        # Za definisanje preprocessing pipeline-a
```

```
##
## Attaching package: 'recipes'
##
## The following object is masked from 'package:stringr':
##
##     fixed
##
## The following object is masked from 'package:stats':
##
##     step
```

```r
library(themis)         # Za balansiranje klasa (SMOTE i druge metode)
library(ranger)         # Brza implementacija Random Forest algoritma
library(ranger)
```

- **tidyverse**: Skup paketa za rad sa podacima, uključujući **dplyr** za manipulaciju, **ggplot2** za vizualizaciju i **readr** za učitavanje podataka. Koristi se za čišćenje, transformaciju i eksploratornu analizu podataka (EDA).

- **caret**: Centralni paket za mašinsko učenje koji omogućava treniranje modela, cross-validaciju, tuning hiperparametara i evaluaciju performansi kroz jedinstven interfejs.

- **pROC**: Paket namenjen izračunavanju i prikazu ROC krivih i AUC metrike, koji omogućava detaljnu evaluaciju klasifikacionih modela.

- **nnet**: Paket koji omogućava implementaciju multinomijalne logističke regresije i jednostavnih neuronskih mreža, pogodan za baseline modele klasifikacije.
- **patchwork**: Paket za kombinovanje više **ggplot2** grafikona u jedinstvenu kompoziciju, što omogućava preglednije i organizovanije vizualizacije.
- **recipes**: Paket za definisanje preprocessing pipeline-a nad podacima, uključujući skaliranje, normalizaciju i druge transformacije na strukturiran i reproduktivan način.
- **themis**: Paket koji proširuje recipes funkcionalnost metodama za balansiranje nebalansiranih skupova podataka, uključujući SMOTE i srodne tehnike.
- **ranger**: Visokoperformantna implementacija Random Forest algoritma, optimizovana za brzinu i efikasnost, sa podrškom za integraciju sa caret paketom i analizu važnosti atributa.
- **xgboost**: Biblioteka za gradient boosting nad stablima odlučivanja, optimizovana za brzinu i skalabilnost, sa podrškom za regularizaciju (L1 i L2), paralelno izvršavanje, rad sa nedostajućim vrednostima i integraciju sa alatima kao što su scikit-learn, R i Spark, uz mogućnost analize važnosti atributa i fine kontrole hiperparametara.

Učitavanje seta podataka

Inicijalizuju se podaci iz eksternog izvora u R okruženju, što predstavlja osnovu za dalju analizu i modelovanje. Ova faza osigurava da se dataset učita efikasno, sa proverom dimenzija i osnovnih statistika, kako bi se potvrdio integritet podataka pre prelaska na EDA i preprocesiranje. Opcija *stringsAsFactors = FALSE* sprečava automatsko pretvaranje tekstualnih kolona u faktore.

```
dataset_path <- "./dataset/Industrial_fault_detection.csv"
dataset <- read.csv(dataset_path, stringsAsFactors = FALSE)

cat(sprintf("Dataset uspešno učitan: %d redova, %d kolona\n",
            nrow(dataset), ncol(dataset)))

## Dataset uspešno učitan: 1000 redova, 37 kolona

summary(dataset)

##   Temperature      Vibration        Pressure        Flow_Rate
##  Min.   :45.64   Min.   :1.621   Min.   : 56.78   Min.   : 4.141
##  1st Qu.:73.65   1st Qu.:2.890   1st Qu.: 97.21   1st Qu.: 8.525
##  Median :75.02   Median :3.041   Median : 99.96   Median :10.000
##  Mean   :75.01   Mean   :3.032   Mean   : 99.94   Mean   : 9.963
##  3rd Qu.:76.46   3rd Qu.:3.183   3rd Qu.:102.80   3rd Qu.:11.334
##  Max.   :82.16   Max.   :3.784   Max.   :112.13   Max.   :16.486
```

```
##     Current         Voltage        FFT_Temp_0      FFT_Vib_0
##  Min.   : 5.47   Min.   :191.0   Min.   :  0.0   Min.   : 0.00
##  1st Qu.:12.95   1st Qu.:213.1   1st Qu.:739.9   1st Qu.:29.37
##  Median :14.95   Median :219.6   Median :749.9   Median :30.30
##  Mean   :14.85   Mean   :219.5   Mean   :743.3   Mean   :30.04
##  3rd Qu.:16.92   3rd Qu.:226.1   3rd Qu.:760.3   3rd Qu.:31.38
##  Max.   :24.34   Max.   :251.0   Max.   :797.3   Max.   :35.70
##    FFT_Pres_0       FFT_Temp_1       FFT_Vib_1        FFT_Pres_1
##  Min.   :   0.0   Min.   : 0.000   Min.   :0.0000   Min.   : 0.00
##  1st Qu.: 977.9   1st Qu.: 7.797   1st Qu.:0.7576   1st Qu.:16.36
##  Median :1000.6   Median :11.763   Median :1.3158   Median :25.03
##  Mean   : 990.9   Mean   :13.381   Mean   :1.3662   Mean   :26.66
##  3rd Qu.:1020.8   3rd Qu.:17.942   3rd Qu.:1.8551   3rd Qu.:35.55
##  Max.   :1091.5   Max.   :39.546   Max.   :4.1063   Max.   :70.92
##    FFT_Temp_2       FFT_Vib_2        FFT_Pres_2      FFT_Temp_3
##  Min.   : 0.000   Min.   :0.0000   Min.   : 0.00   Min.   : 0.000
##  1st Qu.: 8.696   1st Qu.:0.7305   1st Qu.:18.02   1st Qu.: 7.723
##  Median :13.037   Median :1.2668   Median :26.96   Median :12.594
##  Mean   :13.795   Mean   :1.3438   Mean   :28.47   Mean   :13.485
##  3rd Qu.:18.326   3rd Qu.:1.8450   3rd Qu.:37.76   3rd Qu.:18.457
##  Max.   :40.499   Max.   :3.8212   Max.   :83.64   Max.   :35.201
##    FFT_Vib_3       FFT_Pres_3      FFT_Temp_4       FFT_Vib_4
##  Min.   :0.000   Min.   : 0.00   Min.   : 0.000   Min.   :0.0000
##  1st Qu.:0.821   1st Qu.:16.42   1st Qu.: 8.578   1st Qu.:0.8393
##  Median :1.327   Median :26.81   Median :13.956   Median :1.4119
##  Mean   :1.408   Mean   :27.37   Mean   :14.287   Mean   :1.4440
##  3rd Qu.:1.886   3rd Qu.:36.51   3rd Qu.:18.984   3rd Qu.:1.9651
##  Max.   :4.533   Max.   :82.44   Max.   :35.529   Max.   :3.9143
##    FFT_Pres_4      FFT_Temp_5       FFT_Vib_5        FFT_Pres_5
##  Min.   : 0.00   Min.   : 0.000   Min.   :0.0000   Min.   :  0.000
##  1st Qu.:16.75   1st Qu.: 4.240   1st Qu.:0.4635   1st Qu.:  7.838
##  Median :25.98   Median : 9.281   Median :0.9414   Median : 18.288
##  Mean   :27.53   Mean   :11.374   Mean   :1.1691   Mean   : 23.574
##  3rd Qu.:37.22   3rd Qu.:16.906   3rd Qu.:1.6460   3rd Qu.: 33.601
##  Max.   :93.00   Max.   :49.219   Max.   :5.7256   Max.   :103.476
##    FFT_Temp_6       FFT_Vib_6        FFT_Pres_6      FFT_Temp_7
##  Min.   : 0.000   Min.   :0.0000   Min.   : 0.00   Min.   : 0.000
##  1st Qu.: 8.578   1st Qu.:0.8393   1st Qu.:16.75   1st Qu.: 7.723
##  Median :13.956   Median :1.4119   Median :25.98   Median :12.594
##  Mean   :14.287   Mean   :1.4440   Mean   :27.53   Mean   :13.485
##  3rd Qu.:18.984   3rd Qu.:1.9651   3rd Qu.:37.22   3rd Qu.:18.457
##  Max.   :35.529   Max.   :3.9143   Max.   :93.00   Max.   :35.201
##    FFT_Vib_7       FFT_Pres_7      FFT_Temp_8       FFT_Vib_8
##  Min.   :0.000   Min.   : 0.00   Min.   : 0.000   Min.   :0.0000
##  1st Qu.:0.821   1st Qu.:16.42   1st Qu.: 8.696   1st Qu.:0.7305
##  Median :1.327   Median :26.81   Median :13.037   Median :1.2668
##  Mean   :1.408   Mean   :27.37   Mean   :13.795   Mean   :1.3438
##  3rd Qu.:1.886   3rd Qu.:36.51   3rd Qu.:18.326   3rd Qu.:1.8450
##  Max.   :4.533   Max.   :82.44   Max.   :40.499   Max.   :3.8212
##    FFT_Pres_8      FFT_Temp_9       FFT_Vib_9        FFT_Pres_9
```

```
##  Min.   : 0.00   Min.   : 0.000   Min.   :0.0000   Min.   : 0.00
##  1st Qu.:18.02   1st Qu.: 7.797   1st Qu.:0.7576   1st Qu.:16.36
##  Median :26.96   Median :11.763   Median :1.3158   Median :25.03
##  Mean   :28.47   Mean   :13.381   Mean   :1.3662   Mean   :26.66
##  3rd Qu.:37.76   3rd Qu.:17.942   3rd Qu.:1.8551   3rd Qu.:35.55
##  Max.   :83.64   Max.   :39.546   Max.   :4.1063   Max.   :70.92
##    Fault_Type
##  Min.   :0.000
##  1st Qu.:0.000
##  Median :0.000
##  Mean   :0.548
##  3rd Qu.:1.000
##  Max.   :3.000
```

Osnovni senzori (Temperature, Vibration, Pressure, Flow_Rate, Current, Voltage) pokazuju relativno usku distribuciju oko medijana, sa malim odstupanjima od proseka (npr. temperatura: medijana 75.02, prosek 75.01; vibracije: medijana 3.041, prosek 3.032). Ovo ukazuje na stabilna radna stanja većine merenja.

FFT komponente (npr. FFT_Temp_0 do FFT_Pres_9) imaju širok raspon vrednosti, sa značajnim razlikama između nižih i viših binova, što je očekivano za frekventne karakteristike signala. Većina FFT binova pokazuje slične statistike u parovima (npr. bin 2 i bin 7 imaju identične kvartile i prosek), što može ukazivati na simetričnost ili redundantnost u FFT transformaciji.

Ciljna promenljiva Fault_Type ima vrednosti od 0 do 3 (kodirane klase: Normal, Overheating, Leakage, Power Fluctuation). Prosečna vrednost 0.548 i medijana 0.000 sugerišu značajnu nebalansiranost, većinski deo podataka pripada klasi 0 (normalno stanje), što će zahtevati tehniku balansiranja u daljim koracima.

Eksplorativna analiza podataka (EDA)

Eksplorativna analiza podataka predstavlja ključni početni korak u svakom istraživanju iz oblasti nauke o podacima. Njena svrha je da se podaci detaljno istraže, sumiraju i vizuelno prikažu kako bi se otkrile njihove glavne karakteristike, obrasci, anomalije, odnosi između promenljivih i potencijalni problemi.

Osnovne informacije o datasetu

Izvršava se inicijalna inspekcija kvaliteta i strukture podataka, što predstavlja neophodan korak pre detaljnije eksplorativne analize. Ova faza omogućava brzu proveru dimenzija skupa, prisustva duplikata, nedostajućih vrednosti i potpuno praznih redova, kao i pregled tipova promenljivih i osnovnih statistika za ključne senzore.

```r
cat(sprintf("Dimenzije: %d x %d\n", nrow(dataset), ncol(dataset)))

## Dimenzije: 1000 x 37

cat(sprintf("Duplikati: %d\n", sum(duplicated(dataset))))

## Duplikati: 0

cat(sprintf("Nedostajuće vrednosti: %d\n", sum(is.na(dataset))))

## Nedostajuće vrednosti: 0

num_df <- dataset %>% select(where(is.numeric))
zero_rows <- which(rowSums(num_df == 0, na.rm = TRUE) == ncol(num_df))
cat(sprintf("Potpuno prazni redovi: %d\n", length(zero_rows)))

## Potpuno prazni redovi: 0

print(str(dataset))

## 'data.frame':    1000 obs. of  37 variables:
##  $ Temperature: num  46 62.5 77.3 76.6 78.3 ...
##  $ Vibration  : num  2.04 2.57 3.24 3.14 3.14 ...
##  $ Pressure   : num  56.8 76.2 92.4 94.1 94.4 ...
##  $ Flow_Rate  : num  6.18 8.28 9.17 13.78 11.11 ...
##  $ Current    : num  12.4 14.9 15.1 16.4 10.9 ...
##  $ Voltage    : num  216 215 202 217 227 ...
##  $ FFT_Temp_0 : num  772 768 766 764 747 ...
##  $ FFT_Vib_0  : num  32.4 32.4 32 33 33 ...
##  $ FFT_Pres_0 : num  972 962 956 957 950 ...
##  $ FFT_Temp_1 : num  3.76 8.37 9.56 10.25 18.31 ...
##  $ FFT_Vib_1  : num  0.734 0.725 0.934 0.169 0.173 ...
##  $ FFT_Pres_1 : num  30.9 27.3 30.1 29.9 36.1 ...
##  $ FFT_Temp_2 : num  8.79 12.55 12.29 10.32 14.44 ...
##  $ FFT_Vib_2  : num  1.157 1.131 0.803 1.14 1.149 ...
##  $ FFT_Pres_2 : num  4.37 8.1 13.26 13.29 7.15 ...
##  $ FFT_Temp_3 : num  22.09 19.49 21.11 20.86 8.16 ...
```

```
##  $ FFT_Vib_3  : num  1.29 1.283 0.972 0.606 0.627 ...
##  $ FFT_Pres_3 : num  34 41.4 43.4 43.6 45.5 ...
##  $ FFT_Temp_4 : num  2.53 6.94 5.46 6.58 17.85 ...
##  $ FFT_Vib_4  : num  0.437 0.413 0.534 1.169 1.178 ...
##  $ FFT_Pres_4 : num  23.4 25.1 20.2 19.9 14.8 ...
##  $ FFT_Temp_5 : num  2.2 7 5.37 7.4 9.79 ...
##  $ FFT_Vib_5  : num  1.67 1.62 1.99 3 3.02 ...
##  $ FFT_Pres_5 : num  25.8 35.1 29 28.7 22.4 ...
##  $ FFT_Temp_6 : num  2.53 6.94 5.46 6.58 17.85 ...
##  $ FFT_Vib_6  : num  0.437 0.413 0.534 1.169 1.178 ...
##  $ FFT_Pres_6 : num  23.4 25.1 20.2 19.9 14.8 ...
##  $ FFT_Temp_7 : num  22.09 19.49 21.11 20.86 8.16 ...
##  $ FFT_Vib_7  : num  1.29 1.283 0.972 0.606 0.627 ...
##  $ FFT_Pres_7 : num  34 41.4 43.4 43.6 45.5 ...
##  $ FFT_Temp_8 : num  8.79 12.55 12.29 10.32 14.44 ...
##  $ FFT_Vib_8  : num  1.157 1.131 0.803 1.14 1.149 ...
##  $ FFT_Pres_8 : num  4.37 8.1 13.26 13.29 7.15 ...
##  $ FFT_Temp_9 : num  3.76 8.37 9.56 10.25 18.31 ...
##  $ FFT_Vib_9  : num  0.734 0.725 0.934 0.169 0.173 ...
##  $ FFT_Pres_9 : num  30.9 27.3 30.1 29.9 36.1 ...
##  $ Fault_Type : int  0 0 0 0 3 0 0 0 0 1 ...
## NULL
```

```r
print(sapply(dataset, class))
```

```
## Temperature   Vibration    Pressure   Flow_Rate     Current     Voltage
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  FFT_Temp_0   FFT_Vib_0  FFT_Pres_0  FFT_Temp_1   FFT_Vib_1  FFT_Pres_1
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  FFT_Temp_2   FFT_Vib_2  FFT_Pres_2  FFT_Temp_3   FFT_Vib_3  FFT_Pres_3
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  FFT_Temp_4   FFT_Vib_4  FFT_Pres_4  FFT_Temp_5   FFT_Vib_5  FFT_Pres_5
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  FFT_Temp_6   FFT_Vib_6  FFT_Pres_6  FFT_Temp_7   FFT_Vib_7  FFT_Pres_7
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  FFT_Temp_8   FFT_Vib_8  FFT_Pres_8  FFT_Temp_9   FFT_Vib_9  FFT_Pres_9
##   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"   "numeric"
##  Fault_Type
##   "integer"
```

```r
base_sensors <- c("Temperature", "Vibration", "Pressure",
                  "Flow_Rate", "Current", "Voltage")

print(summary(dataset %>% select(all_of(base_sensors))))
```

```
##   Temperature      Vibration        Pressure        Flow_Rate
##  Min.   :45.64   Min.   :1.621   Min.   : 56.78   Min.   : 4.141
##  1st Qu.:73.65   1st Qu.:2.890   1st Qu.: 97.21   1st Qu.: 8.525
##  Median :75.02   Median :3.041   Median : 99.96   Median :10.000
##  Mean   :75.01   Mean   :3.032   Mean   : 99.94   Mean   : 9.963
##  3rd Qu.:76.46   3rd Qu.:3.183   3rd Qu.:102.80   3rd Qu.:11.334
```

```
##  Max.   :82.16   Max.   :3.784   Max.   :112.13   Max.   :16.486
##     Current         Voltage
##  Min.   : 5.47   Min.   :191.0
##  1st Qu.:12.95   1st Qu.:213.1
##  Median :14.95   Median :219.6
##  Mean   :14.85   Mean   :219.5
##  3rd Qu.:16.92   3rd Qu.:226.1
##  Max.   :24.34   Max.   :251.0
```

Rezultati pokazuju da dataset sadrži 1000 posmatranja i 37 promenljivih, bez duplikata, nedostajućih vrednosti ili potpuno praznih redova, što ukazuje na visok kvalitet i spremnost podataka za dalju analizu. Sve prediktorske promenljive su numeričkog tipa (numeric), dok je ciljna promenljiva Fault_Type celobrojna (integer). Deskriptivna statistika osnovnih senzora (Temperature, Vibration, Pressure, Flow_Rate, Current, Voltage) pokazuje stabilne vrednosti sa malim rasponom odstupanja oko medijane, što je karakteristično za normalna radna stanja industrijske opreme.

Analiza ciljne varijable (Fault_Type)

Vrši se detaljna inspekcija distribucije ciljne promenljive, koja predstavlja tip kvara u industrijskom sistemu. Ova analiza je ključna jer nebalansiranost klasa može značajno uticati na performanse modela klasifikacije, dovodeći do pristrasnosti prema dominantnoj klasi. Prvo se numerička promenljiva Fault_Type pretvara u faktor sa smislenim labelama, zatim se izračunavaju apsolutne i relativne frekvencije, a na kraju se kreira vizuelizacija distribucije pomoću ggplot2 paketa.

```
dataset$Fault_Type <- factor(
  dataset$Fault_Type,
  levels = c("0", "1", "2", "3"),
  labels = c("Normal", "Overheating", "Leakage", "Power_Fluctuation")
)

fault_table <- table(dataset$Fault_Type)
fault_prop <- prop.table(fault_table)
print(round(fault_prop * 100, 2))

##
##            Normal       Overheating           Leakage Power_Fluctuation
##              72.5               9.1               9.5               8.9

freq_df <- data.frame(
  Fault_Type = names(fault_table),
  Freq = as.numeric(fault_table),
  Perc = round(as.numeric(fault_prop) * 100, 1)
)

plot_distribution <- ggplot(freq_df, aes(x = Fault_Type, y = Freq, fill = Fau
lt_Type)) +
  geom_col() +
  geom_text(aes(label = paste0(Perc, "%")), vjust = -0.3, size = 4) +
  labs(title = "Distribucija klasa (u procentima)",
       x = "Tip kvara",
       y = "Broj posmatranja") +
  ylim(0, max(freq_df$Freq) * 1.15) +
  theme_grid_readable()

plot_distribution
```

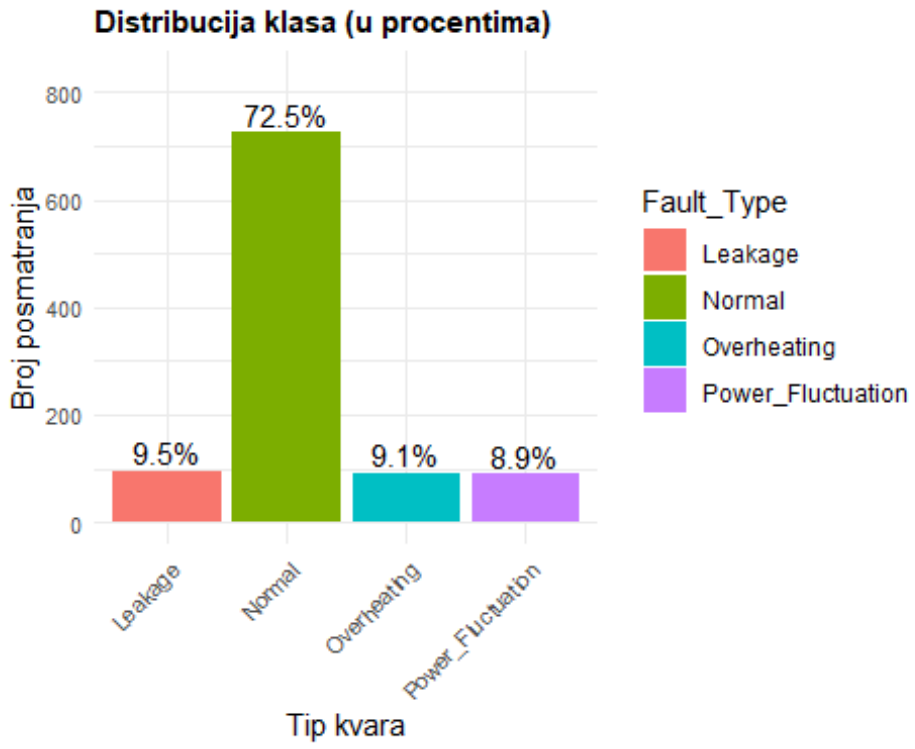

Distribucija ciljne promenljive Fault_Type pokazuje izrazitu nebalansiranost: klasa “Normal” čini 72.5% svih posmatranja, dok su ostale klase značajno manje zastupljene: “Leakage” 9.5%, “Overheating” 9.1% i “Power_Fluctuation” 8.9%. Ova disproporcija je očekivana u realnim industrijskim podacima, gde normalno stanje dominira, ali predstavlja ozbiljan izazov za modele mašinskog učenja. Bez adekvatnog balansiranja, modeli bi imali tendenciju da predviđaju dominantnu klasu “Normal” sa visokom tačnošću, ali sa lošim performansama na manjinskim klasama kvarova. Vizuelizacija distribucije jasno ilustruje ovu neravnotežu i naglašava potrebu za tehnikama balansiranja u fazi preprocesiranja.

Generisanje histograma osnovnih senzora

Ovde se vrši vizualizacija distribucija šest primarnih senzorskih promenljivih (Temperature, Vibration, Pressure, Flow_Rate, Current, Voltage), što omogućava uvid u oblik, centralnu tendenciju, raspršenost i eventualnu asimetriju podataka. Ovi histogrami su ključni za identifikaciju karakteristika normalnog rada opreme, detekciju odstupanja i procenu pogodnosti za dalje statističke analize ili modelovanje.

```
sensor_plots <- lapply(base_sensors, function(var) {
  ggplot(dataset, aes_string(x = var)) +
    geom_histogram(color = "black", fill = "lightblue", bins = 30, alpha = 0.
7) +
    labs(title = paste("Histogram:", var), x = var, y = "Frekvencija") +
    theme_grid_readable() +
    theme(legend.position = "none")
})

## Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
## ℹ Please use tidy evaluation idioms with `aes()`.
## ℹ See also `vignette("ggplot2-in-packages")` for more information.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.

combined_histograms <- wrap_plots(sensor_plots, ncol = 2)
combined_histograms
```

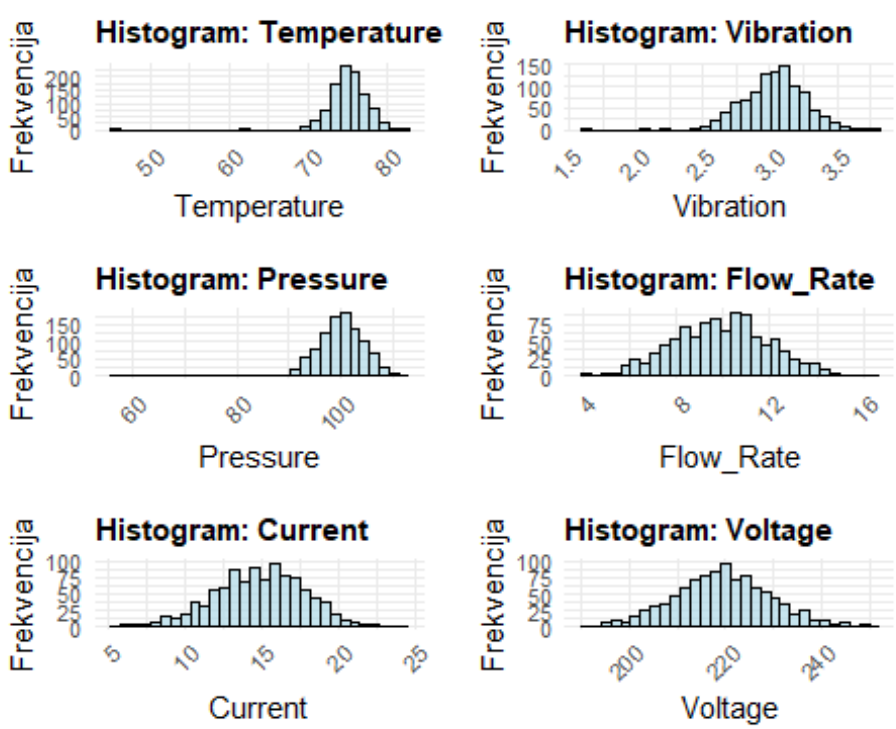

Histogrami pokazuju da su distribucije osnovnih senzora uglavnom unimodalne i blago asimetrične, sa koncentracijom vrednosti oko medijane (npr. temperatura oko 75 °C, vibracije oko 3.0 m/s^2, pritisak oko 100 jedinica). Temperatura i pritisak imaju relativno uske raspone sa izraženim vrhom u srednjem delu, što ukazuje na stabilna radna stanja. Vibracije i protok (Flow_Rate) pokazuju nešto širu distribuciju sa blagim repom ka višim vrednostima, dok struja (Current) i napon (Voltage) imaju više izraženu asimetriju sa dužim repom ka višim vrednostima, što može odgovarati epizodama fluktuacija ili kvarova. Odsustvo izrazitih bimodalnih oblika sugeriše da većina merenja pripada normalnom režimu rada, dok ekstremne vrednosti (posebno u repovima) verovatno odgovaraju retkim kvarovima. Ovi nalazi potvrđuju potrebu za pažljivim skaliranjem i feature engineering-om u narednim fazama, jer senzori imaju različite skale i varijabilnost.

Boxplotovi senzora u odnosu na Fault_Type

Vrši se grupisana vizualizacija distribucija šest osnovnih senzorskih promenljivih (Temperature, Vibration, Pressure, Flow_Rate, Current, Voltage) prema tipu kvara. Boxplotovi omogućavaju direktno poređenje centralnih tendencija (medijana), raspršenosti (IQR), ekstremnih vrednosti i outlier-a između klasa, čime se otkrivaju potencijalni diskriminativni obrasci između normalnog stanja i različitih tipova kvarova.

```
boxplot_plots <- lapply(base_sensors, function(var) {
  ggplot(dataset, aes_string(x = "Fault_Type", y = var, fill = "Fault_Type"))
+
    geom_boxplot(alpha = 0.7) +
    labs(title = paste(var, "po tipu kvara"), x = "Tip kvara", y = var) +
    theme_grid_readable() + theme(legend.position = "none")
})
combined_boxplots <- wrap_plots(boxplot_plots, ncol = 2)
combined_boxplots
```

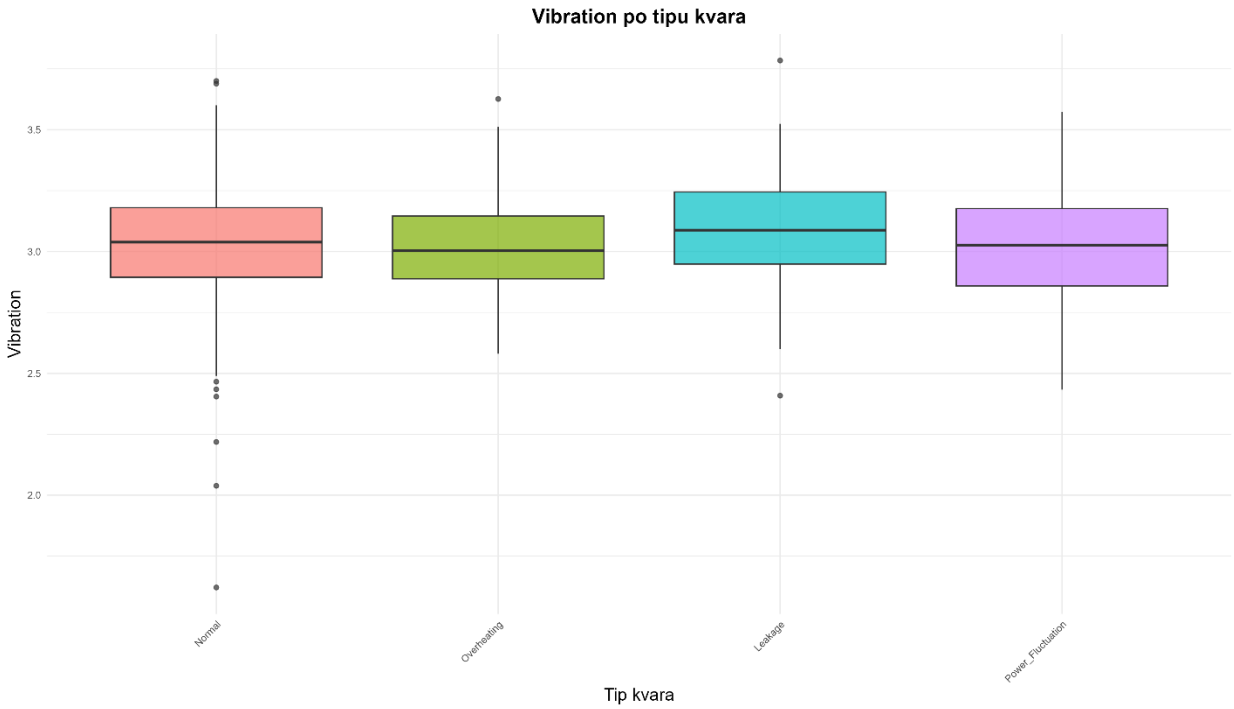
Vibration po tipu kvara
Vibration
3.5
3.0
2.5
2.0
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

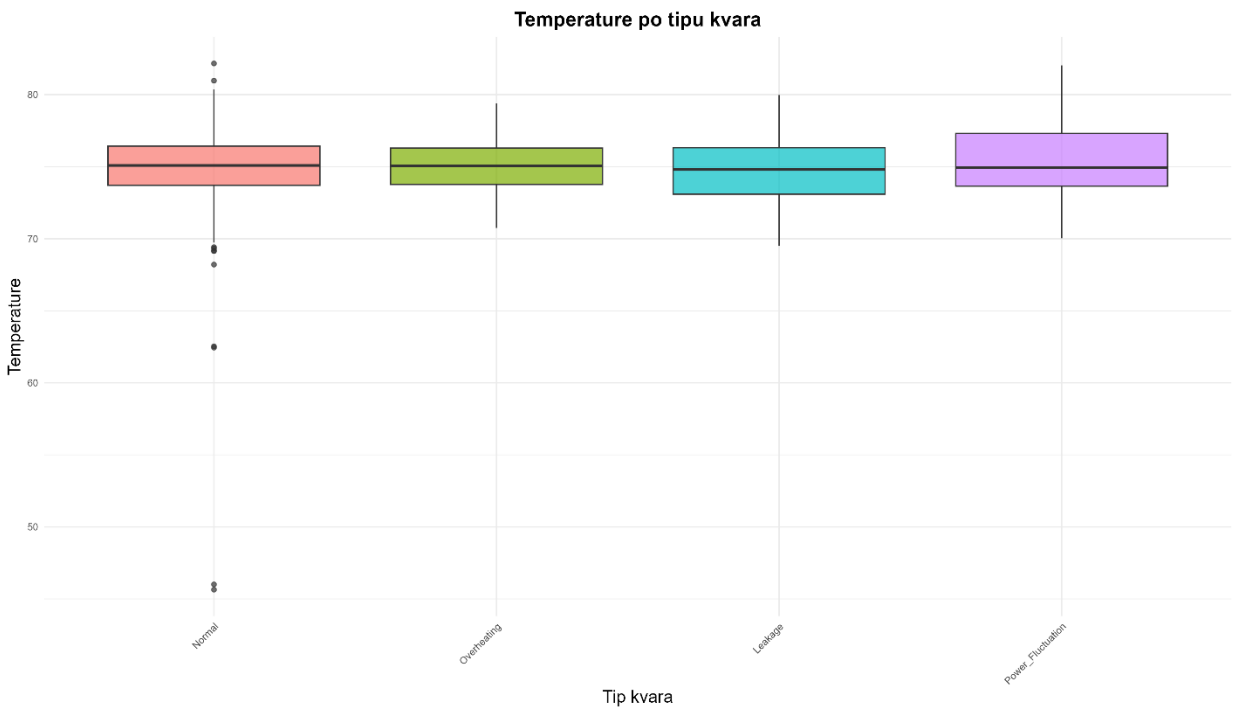
Temperature po tipu kvara
Temperature
80
70
60
50
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

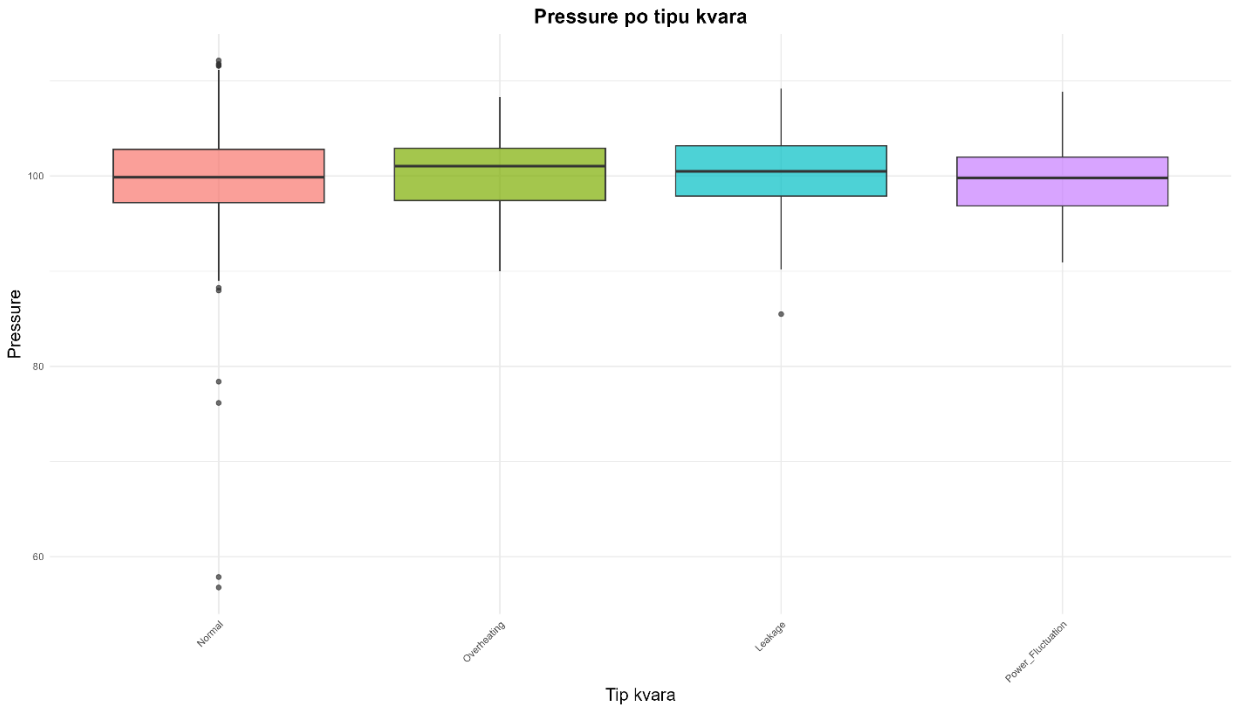
Pressure po tipu kvara
Pressure
100
80
60
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

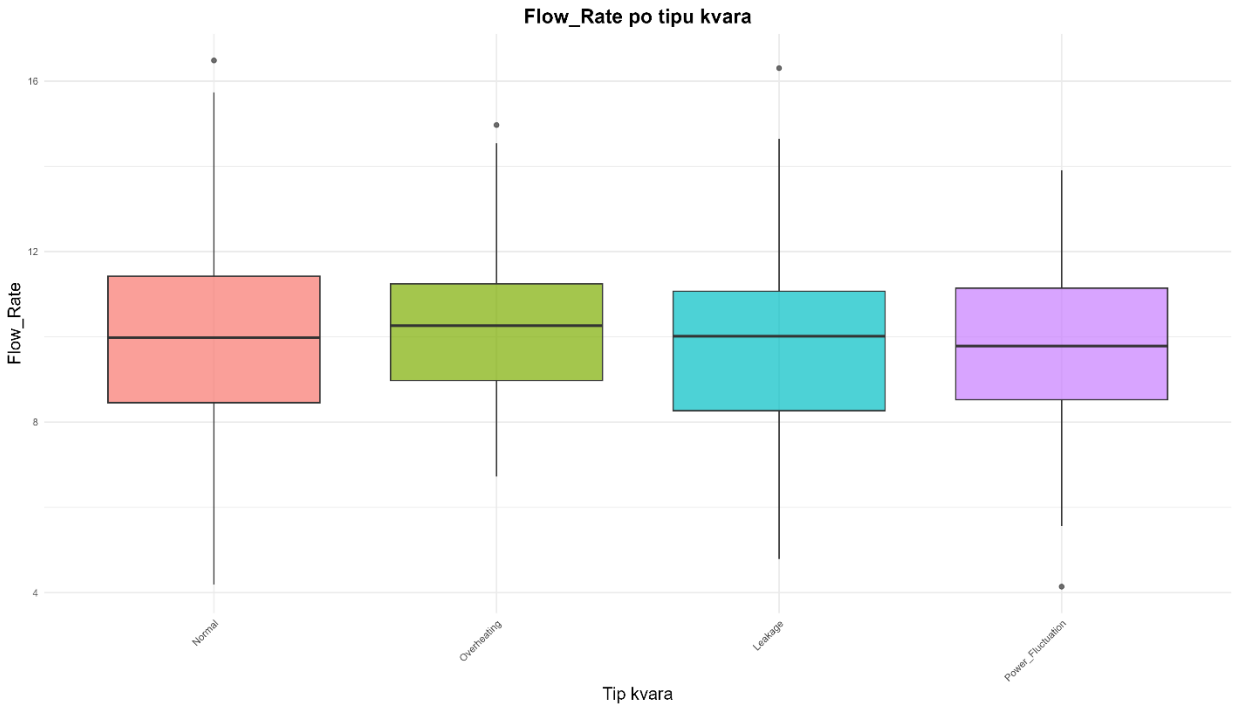
Flow_Rate po tipu kvara
Flow_Rate
16
12
8
4
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

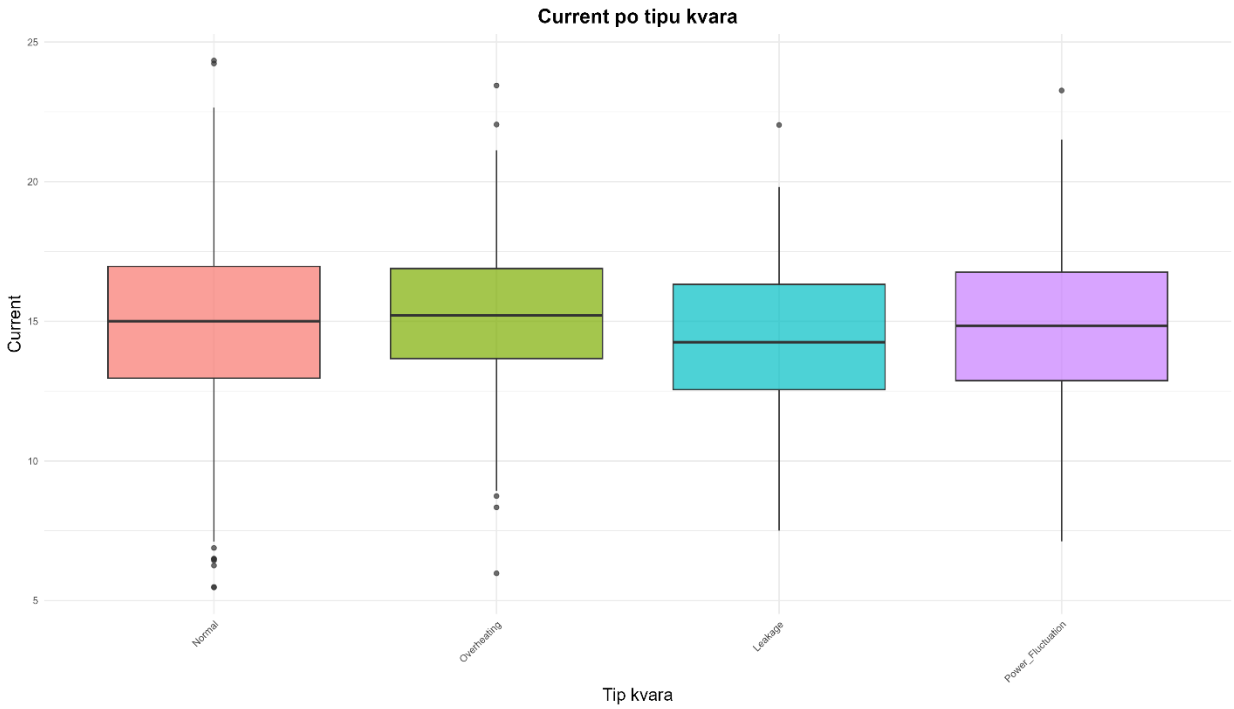
Current po tipu kvara
Current
25
20
15
10
5
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

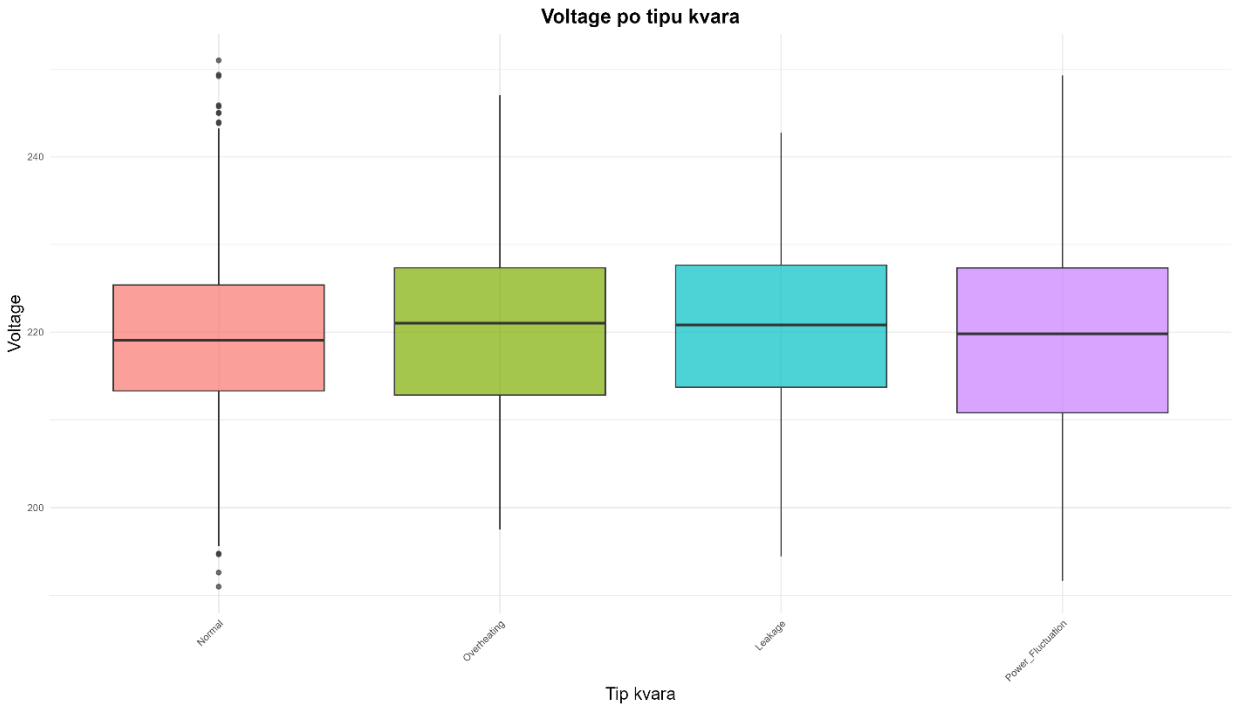
Voltage po tipu kvara
Voltage
240
220
200
Normal
Overheating
Leakage
Power_Fluctuation
Tip kvara

Boxplotovi pokazuju jasne razlike u ponašanju senzora između klasa:

- Temperature: Najviša medijana i najveći raspon u klasi “Overheating”, sa izraženim outlier-ima ka višim vrednostima, što je očekivano za pregrevanje. Klase “Normal” i “Leakage” imaju slične, niže vrednosti.
- Vibration: Nešto više vrednosti i veća varijabilnost u klasama “Leakage” i “Overheating”, dok je “Normal” najstabilniji sa manjim outlier-ima.
- Pressure i Flow_Rate: Relativno slične distribucije među klasama, sa blago nižim medijanama u “Power_Fluctuation” i “Leakage”, ali bez dramatičnih razlika.
- Current i Voltage: Veća varijabilnost i outlier-i u “Normal” i “Overheating”, dok su “Leakage” i “Power_Fluctuation” stabilniji sa nižim medijanama, što može ukazivati na fluktuacije napajanja.

Ovi grafikoni jasno ističu da senzori Temperature i Vibration imaju najjači diskriminativni potencijal za razlikovanje kvarova od normalnog stanja, dok ostali senzori pokazuju manje izražene razlike. Ova saznanja su važna za usmeravanje feature selekcije i inženjeringa u narednim fazama rada.

Deskriptivna statistika po grupama

Jedan od osnovnih koraka u analizi podataka za nadziranu klasifikaciju kvarova jeste sticanje jasnog uvida u univarijatno ponašanje svakog senzora u različitim klasama (Normal, Overheating, Leakage, Power_Fluctuation). Deskriptivna statistika po grupama omogućava kvantifikaciju centralne tendencije (srednja vrednost, medijana) i njene promene između zdravog stanja i kvarova,procenu nivoa varijabilnosti (standardna devijacija, interkvartilni raspon) i eventualne promene stabilnosti signala, identifikaciju sistematskih pomaka u ekstremnim vrednostima (minimum, maksimum) koji često nose najjaču diskriminativnu informaciju, uvid u stepen preklapanja raspodela između klasa, što direktno utiče na očekivanu težinu problema klasifikacije, usmeravanje daljih koraka (odabir najperspektivnijih senzora, detekciju kandidata za inženjering novih obeležja i planiranje multivarijatnih analiza).

```
for (sensor in base_sensors) {

  cat("\nSENZOR:", sensor, "\n")

  sensor_stats <- dataset %>%
    group_by(Fault_Type) %>%
    summarise(
      Mean = mean(.data[[sensor]]),
      SD   = sd(.data[[sensor]]),
      Min  = min(.data[[sensor]]),
      Q25  = quantile(.data[[sensor]], 0.25),
      Med  = median(.data[[sensor]]),
      Q75  = quantile(.data[[sensor]], 0.75),
      Max  = max(.data[[sensor]])
```

```r
    )

  print(sensor_stats)
}
```

```
##
## SENZOR: Temperature
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             75.0  2.72  45.6  73.7  75.1  76.4  82.2
## 2 Overheating        75.2  1.83  70.7  73.8  75.0  76.3  79.4
## 3 Leakage            74.7  2.30  69.5  73.1  74.8  76.3  80.0
## 4 Power_Fluctuation  75.3  2.47  70.0  73.6  74.9  77.3  82.0
##
## SENZOR: Vibration
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             3.03 0.232  1.62  2.89  3.04  3.18  3.70
## 2 Overheating        3.02 0.207  2.58  2.89  3.00  3.15  3.63
## 3 Leakage            3.08 0.238  2.41  2.95  3.09  3.24  3.78
## 4 Power_Fluctuation  3.02 0.218  2.43  2.86  3.03  3.18  3.57
##
## SENZOR: Pressure
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             99.9  5.04  56.8  97.2  99.9  103.  112.
## 2 Overheating       100.   4.02  90.0  97.4 101.   103.  108.
## 3 Leakage           100.   4.12  85.5  97.9 100.   103.  109.
## 4 Power_Fluctuation  99.5  3.95  90.9  96.8  99.8  102.  109.
##
## SENZOR: Flow_Rate
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             9.97  2.06  4.19  8.45  9.99  11.4  16.5
## 2 Overheating       10.3   1.90  6.72  8.98 10.3   11.2  15.0
## 3 Leakage            9.82  2.21  4.79  8.27 10.0   11.1  16.3
## 4 Power_Fluctuation  9.69  1.95  4.14  8.53  9.79  11.1  13.9
##
## SENZOR: Current
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             14.9  2.97  5.47  13.0  15.0  17.0  24.3
## 2 Overheating        15.0  3.03  5.98  13.7  15.2  16.9  23.4
## 3 Leakage            14.5  2.74  7.51  12.6  14.3  16.3  22.0
## 4 Power_Fluctuation  14.9  3.24  7.13  12.9  14.8  16.8  23.3
```

```
##
## SENZOR: Voltage
## # A tibble: 4 × 8
##   Fault_Type         Mean    SD   Min   Q25   Med   Q75   Max
##   <fct>             <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 Normal             219.  9.76  191.  213.  219.  225.  251.
## 2 Overheating        220. 10.8   198.  213.  221.  227.  247.
## 3 Leakage            220.  9.93  194.  214.  221.  228.  243.
## 4 Power_Fluctuation  219. 11.9   192.  211.  220.  227.  249.
```

Prosečne vrednosti i medijane većine senzora pokazuju veoma male razlike među klasama (obično < 2–3% u odnosu na nominalnu vrednost). To ukazuje da analizirani kvarovi ne izazivaju izrazite pomake u prosečnom nivou signala.

Najkonzistentniji i najizraženiji obrazac je značajno povišen minimum u svim kvarnim klasama u poređenju sa normalnim stanjem. Ovaj fenomen se javlja kod:

- Temperature: Normal 45.6 → kvarovi 69.5–70.7 °C
- Vibration: Normal 1.62 → kvarovi 2.41–2.58
- Pressure: Normal 56.8 → kvarovi 85.5–90.9
- Current: Normal 5.47 → kvarovi 5.98–7.51

Na univarijatnom nivou preklapanje raspodela između klasa je značajno, što znači da nijedan senzor sam po sebi ne omogućava pouzdanu separaciju sve četiri klase. Najperspektivniji senzori za diskriminaciju su:

- Flow_Rate – najjači signal za razlikovanje Overheating (↑) i Power_Fluctuation (↓),
- Voltage – najjači indikator nestabilnosti u Power_Fluctuation i Overheating,
- Vibration i Current – najizraženiji za Leakage,
- Temperature – korisna za Overheating (odsustvo niskih vrednosti i blago pomerena distribucija naviše).

Ključni univerzalni indikator prisustva kvara (bez obzira na tip) jeste odsustvo ekstremno niskih vrednosti kod Temperature, Vibration, Pressure i Current.

Analiza korelacije između osnovnih senzorskih promenljivih

Iako se u većini savremenih klasifikacionih zadataka koriste nelinearni modeli koji mogu uhvatiti složene zavisnosti, informacija o linearnim korelacijama i dalje pruža važne uvide:

- otkriva potencijalnu multicolinearnost koja može uticati na interpretabilnost linearnih i logističkih modela,
- ukazuje na parove senzora koji nose redundantnu informaciju,
- pomaže u identifikaciji najslabije povezanih promenljivih koje mogu doprineti raznovrsnosti ulaznih obeležja,
- služi kao polazna tačka za odluku o zadržavanju ili kombinovanju promenljivih u fazi feature selection i feature engineering.

U ovom slučaju izračunaćemo Pearsonovu korelacionu matricu na celokupnom skupu podataka, bez stratifikacije po klasama kvara, kako bi se dobio opšti pregled međusobne povezanosti osnovnih senzora.

```
cor_base <- cor(dataset %>% select(all_of(base_sensors)))
cor_df <- as.data.frame(as.table(cor_base))
colnames(cor_df) <- c("Var1", "Var2", "Cor")

plot_cor <- ggplot(cor_df, aes(x = Var1, y = Var2, fill = Cor)) +
  geom_tile() +
  geom_text(aes(label = sprintf("%.2f", Cor)), size = 3) +
  theme_grid_readable()

plot_cor
```

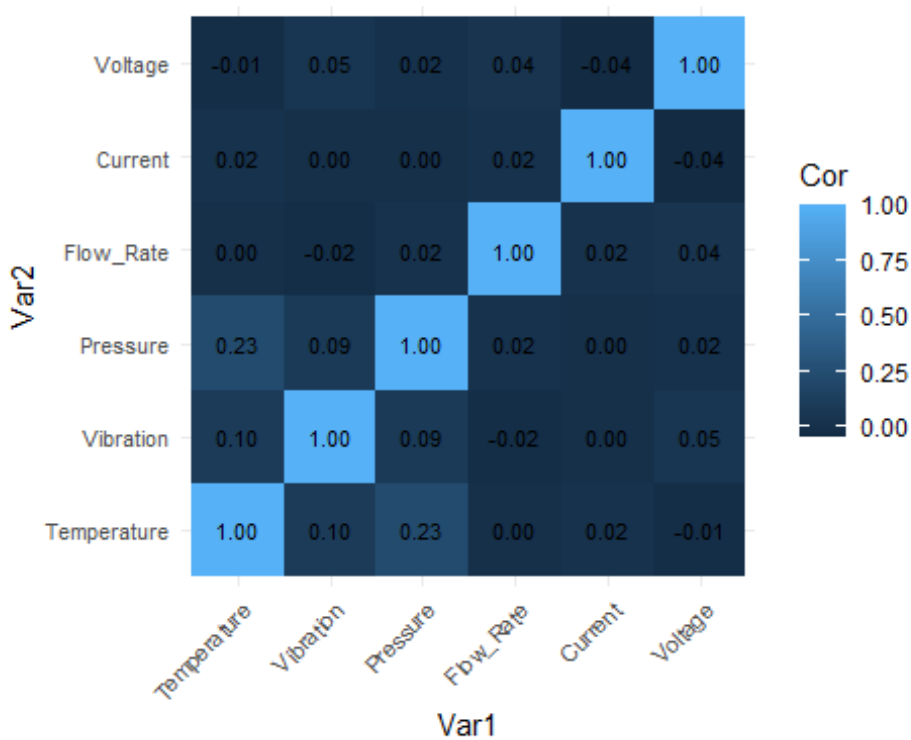


```r
tmp_cor <- cor_base
tmp_cor[lower.tri(tmp_cor, diag = TRUE)] <- NA

top_pairs <- as.data.frame(as.table(tmp_cor)) %>%
  drop_na() %>%
  transmute(
    Varijabla_1 = Var1,
    Varijabla_2 = Var2,
    Korelacija = round(Freq, 3),
    AbsKorelacija = round(abs(Freq), 3)
  ) %>%
  arrange(desc(AbsKorelacija)) %>%
  head(5)

cat("Najizraženiji parovi (top 5 po korelaciji, bez dijagonale):\n")

## Najizraženiji parovi (top 5 po korelaciji, bez dijagonale):

print(top_pairs)

##   Varijabla_1 Varijabla_2 Korelacija AbsKorelacija
## 1 Temperature    Pressure      0.233         0.233
## 2 Temperature   Vibration      0.101         0.101
## 3   Vibration    Pressure      0.085         0.085
## 4   Vibration     Voltage      0.048         0.048
## 5     Current     Voltage     -0.042         0.042
```

```r
max_abs <- top_pairs$AbsKorelacija[1]
cat(sprintf("- Najveća apsolutna korelacija među osnovnim senzorima je %.3f.\
n", max_abs))

## - Najveća apsolutna korelacija među osnovnim senzorima je 0.233.
```

Izračunata matrica za šest osnovnih senzora (*Temperature, Vibration, Pressure, Flow_Rate, Current, Voltage*) pokazuje veoma nizak nivo linearne povezanosti. Najveća apsolutna vrednost korelacije iznosi **0.233** i javlja se između temperature i pritiska.Najizraženiji parovi po apsolutnoj vrednosti korelacije (bez dijagonale) su:

- Temperature – Pressure: 0.233
- Temperature – Vibration: 0.101
- Vibration – Pressure: 0.085
- Vibration – Voltage: 0.048
- Current – Voltage: –0.042

Ostale kombinacije pokazuju korelacije čija apsolutna vrednost ne prelazi 0.04, što se smatra zanemarljivim. Ovi rezultati ukazuju na to da svaki senzor donosi relativno nezavisnu informaciju, što je povoljan scenario za obuku modela.

Vizuelna analiza distribucija po tipovima kvara

Kako bismo dublje razumeli kako se ove vrednosti ponašaju u zavisnosti od stanja sistema, generisani su kombinovani *scatter* i *boxplot* dijagrami za svaki senzor.

```
for (sensor in base_sensors) {
  p_facet <- ggplot(dataset, aes(x = Fault_Type, y = .data[[sensor]])) +
    geom_jitter(width = 0.25, height = 0, alpha = 0.5, size = 1.5) +
    geom_boxplot(outlier.shape = NA, alpha = 0.3, width = 0.6) +
    labs(
      title = paste("Sensor:", sensor),
      y = sensor,
      x = "Fault Type"
    ) +
    theme_minimal() +
    theme(
      axis.text.x = element_text(angle = 45, hjust = 1),
      plot.title = element_text(hjust = 0.5, face = "bold")
    )

  save_and_print(
    p_facet,
    paste0("Scatter_Boxplot_", sensor, ".png"),
    w = 10,
    h = 6
  )
}
```

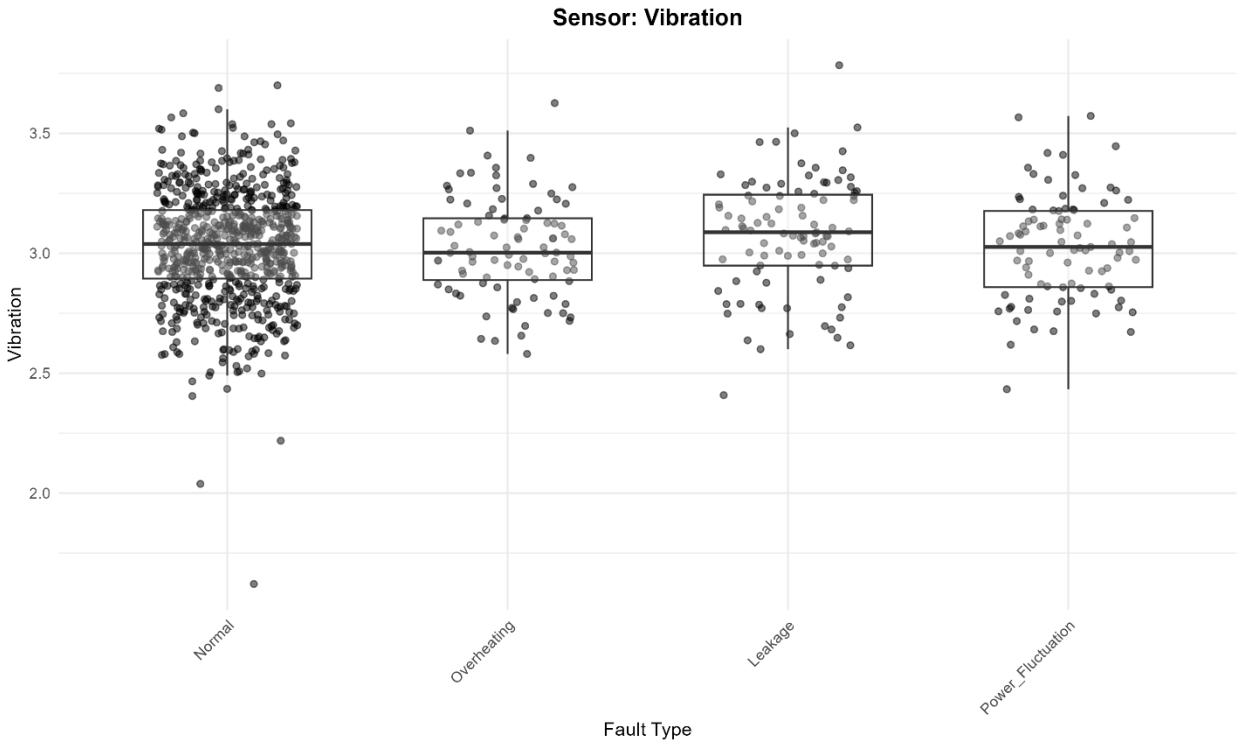
Sensor: Vibration
Vibration
3.5
3.0
2.5
2.0
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

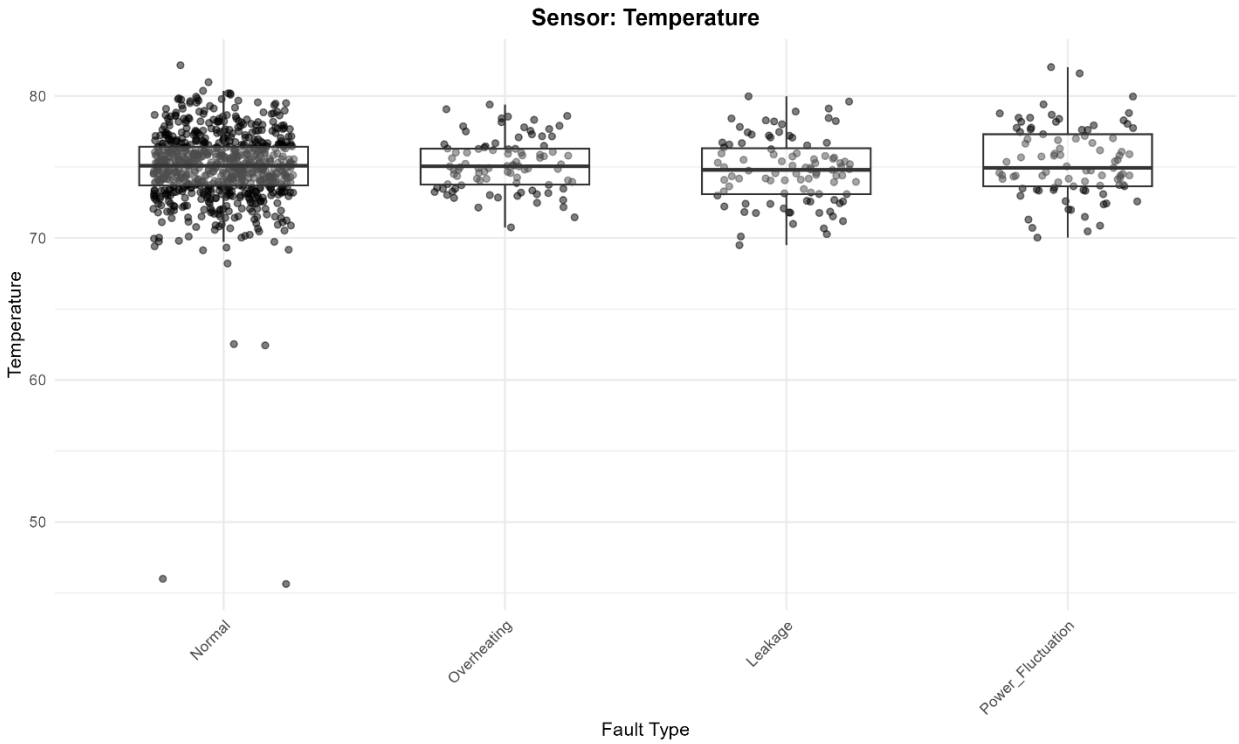
Sensor: Temperature
Temperature
80
70
60
50
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

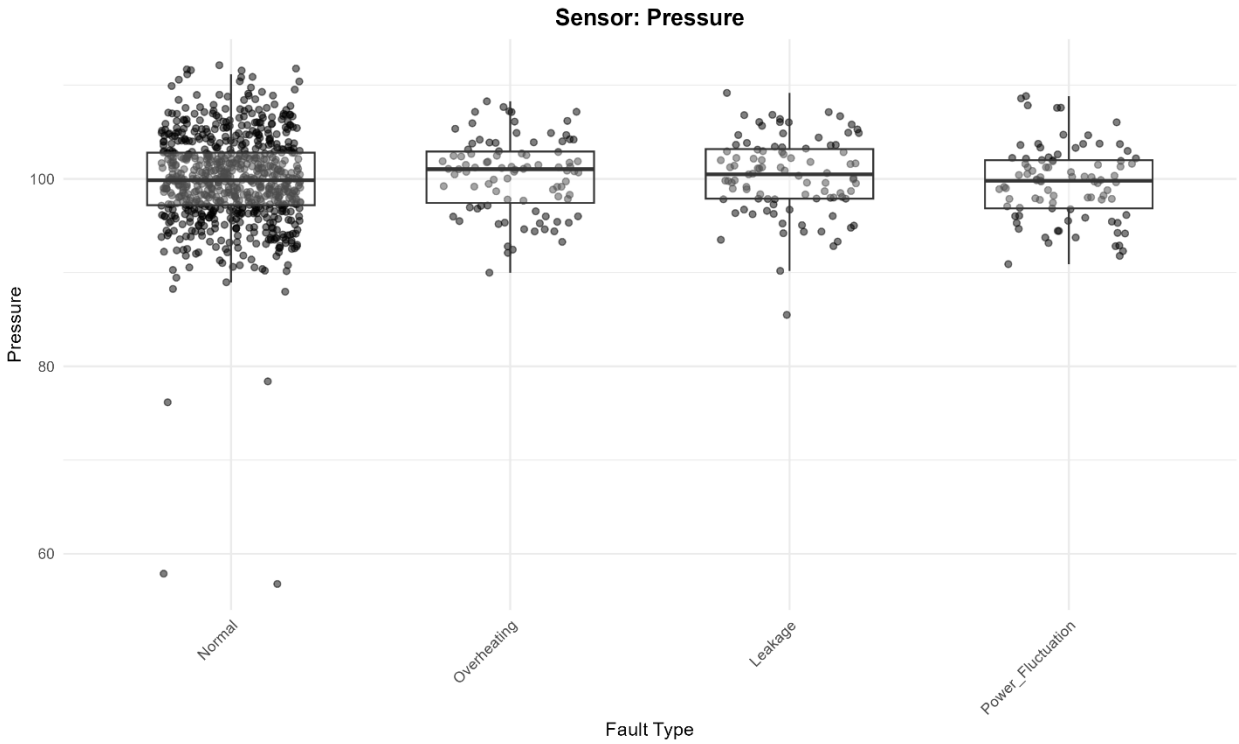
Sensor: Pressure
Pressure
100
80
60
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

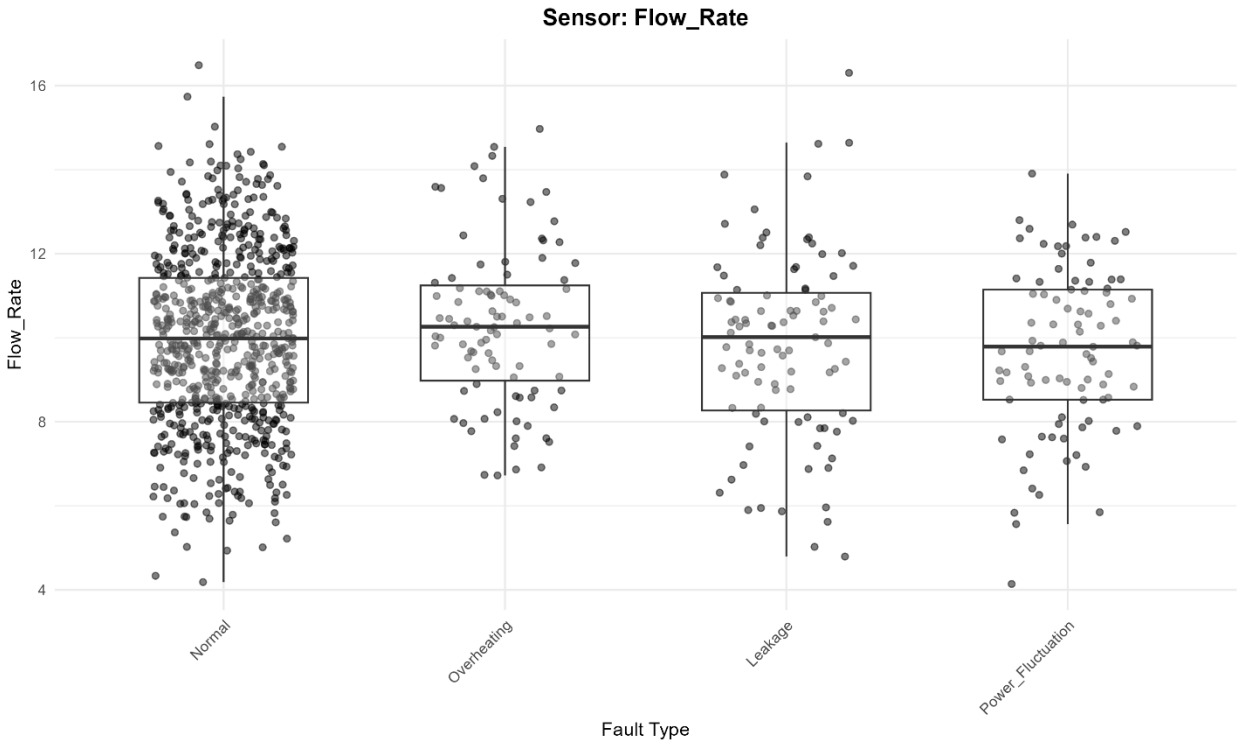
Sensor: Flow_Rate
Flow_Rate
16
12
8
4
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

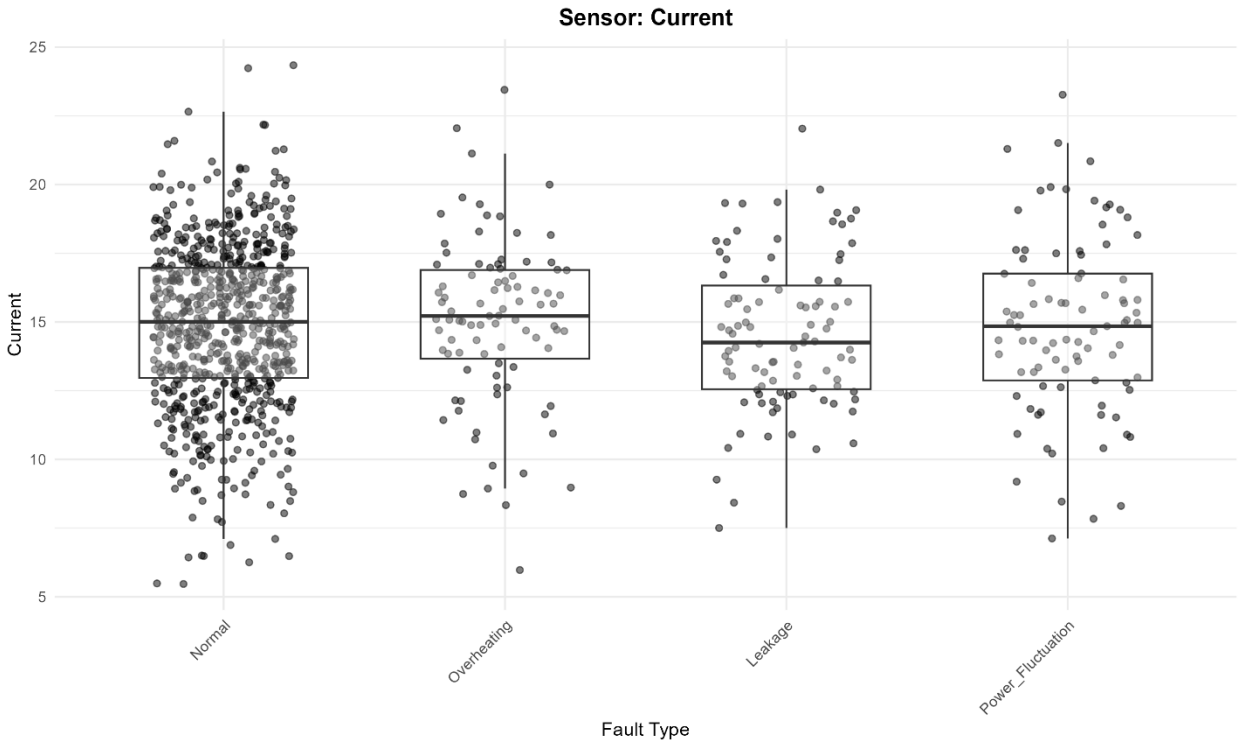
Sensor: Current
Current
25
20
15
10
5
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

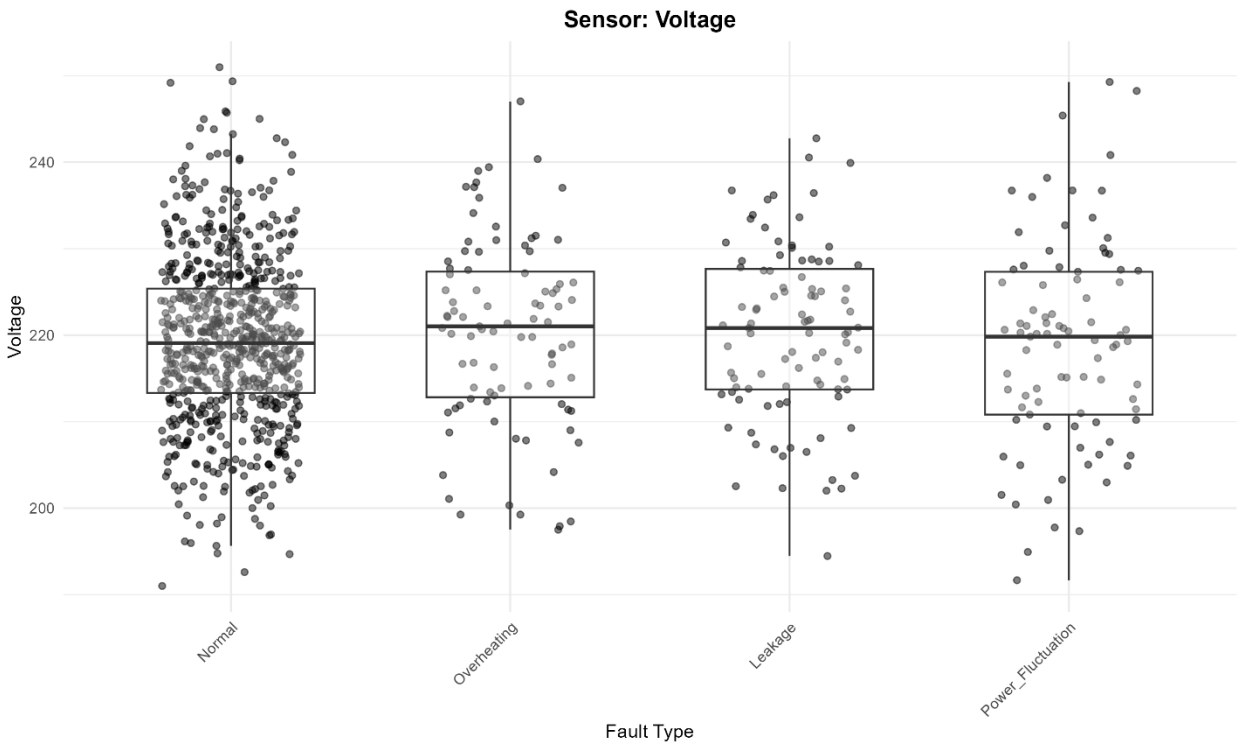
Sensor: Voltage
Voltage
240
220
200
Normal
Overheating
Leakage
Power_Fluctuation
Fault Type

Posmatranjem grafika za senzore (Voltage, Current, Flow_Rate, Pressure, Temperature i Vibration), možemo izvesti nekoliko ključnih zaključaka:

- **Preklapanje distribucija:** Najuočljivija karakteristika svih senzora je izuzetno veliko preklapanje kvartila i medijana između "Normal" stanja i različitih tipova kvara (*Overheating, Leakage, Power_Fluctuation*). To potvrđuje našu pretpostavku iz korelacione analize – nijedna promenljiva sama po sebi, linearno posmatrano, nije dovoljna da jasno razgraniči kvar od normalnog rada.
- **Stabilnost medijana:** Za senzore kao što su *Flow_Rate* i *Voltage*, medijane su gotovo identične za sve četiri klase. To sugeriše da se kvarovi u sistemu ne manifestuju kroz proste promene prosečnih vrednosti ovih parametara, već verovatno kroz složenije interakcije ili promenu varijanse u kraćim vremenskim intervalima.
- **Prisustvo autlajera (Outliers):** Na graficima za *Pressure* i *Temperature* uočljivi su ekstremni autlajeri kod normalnog stanja, gde vrednosti padaju značajno ispod uobičajenog opsega. Ovi podaci mogu ukazivati na senzorske greške ili specifične prelazne režime rada koji ne predstavljaju nužno kvar, ali mogu "zbuniti" jednostavnije algoritme.
- **Specifičnost vibracija i temperature:** Kod kvara tipa *Overheating*, opseg vrednosti vibracija i temperature je nešto uži u poređenju sa normalnim stanjem, ali i dalje duboko unutar granica normale, što ukazuje na to da su anomalije u ovom sistemu suptilne.

Ova nezavisnost senzora, potvrđena i niskom korelacijom i vizuelnim preklapanjem, posebno je korisna u kontekstu klasifikacije. Ona ukazuje na to da kombinovanje više senzora može značajno povećati diskriminativnu moć modela, jer svaki senzor "vidi" drugačiji aspekt procesa.

Slabost direktnih linearnih veza i preklapanje distribucija sugeriše da će **nelinearni modeli** (npr. *Random Forest, Gradient Boosting* ili *neuronske mreže*) verovatno imati značajnu prednost nad linearnim klasifikatorima, jer će morati da traže kompleksne granice odlučivanja u višedimenzionalnom prostoru obeležja.

Provera fizički nelogičnih i nemogućih vrednosti

Pre prelaska na naprednije analize i modelovanje, neophodno je izvršiti sistematsku proveru da li u skupu podataka postoje vrednosti koje su fizički nemoguće ili izrazito nelogične s obzirom na prirodu merenih veličina. Takve vrednosti mogu nastati kao posledica grešaka u senzorskom sistemu, problema pri prikupljanju podataka, prekida komunikacije, softverskih bagova ili grešaka pri obradi i učitavanju podataka.

U kontekstu industrijskog monitoringa, sledeće vrednosti se smatraju fizički nemogućim ili visoko sumnjivim:

- **Temperature** ≤ 0 °C (u većini realnih sistema rashladna tečnost ili okruženje ne dozvoljavaju ovako niske vrednosti bez specijalnih uslova),
- **Pressure** ≤ 0 (apsolutni pritisak ne može biti negativan; čak i gage pritisak retko pada ispod nule u ovakvim sistemima),
- **Voltage** ≤ 0 (AC napon u sistemu napajanja ne može biti negativan u smislu efektivne vrednosti; DC sistemi obično imaju strogo pozitivne vrednosti),
- **Flow_Rate** < 0 (protok tečnosti ili gasa u jednom smeru ne može biti negativan osim ako senzor nije eksplicitno dvosmeran, što ovde nije slučaj),
- **Current** < 0 (efektivna vrednost struje u AC sistemu ne može biti negativna; DC struja može biti negativna samo ako je smer definisan, ali u kontekstu monitoringa opreme obično se uzima apsolutna vrednost).

Provera je izvršena primenom jednostavnih logičkih uslova na pet ključnih senzorskih promenljivih:

```
invalid_temp    <- which(dataset$Temperature <= 0)
invalid_pressure <- which(dataset$Pressure <= 0)
invalid_voltage  <- which(dataset$Voltage <= 0)
invalid_flow     <- which(dataset$Flow_Rate < 0)
invalid_current  <- which(dataset$Current < 0)

invalid_rows <- unique(c(invalid_temp, invalid_pressure, invalid_voltage,
                         invalid_flow, invalid_current))
```

Provera je pokazala da u celokupnom skupu podataka **nema nijednog reda** koji sadrži fizički nemoguću vrednost prema definisanim kriterijumima.Ovo je veoma povoljan rezultat i ukazuje da su podaci u pogledu osnovnih fizičkih ograničenja čisti i ne sadrže očigledne artefakte tipa „-999“, „0“ umesto NA, ili negativne vrednosti koje nemaju fizičko opravdanje.

Zaključno, skup podataka prolazi osnovnu proveru fizičke logičnosti bez ikakvih problema.

Analiza FFT karakteristika (Temperature, Vibration, Pressure)

Brza Furijeova transformacija (FFT) primenjena je na vremenske nizove tri senzora – Temperature, Vibration i Pressure radi izdvajanja frekventnih karakteristika signala. Svaki senzor je transformisan u 10 FFT binova (indeksi 0–9), pri čemu bin 0 odgovara DC komponenti (prosečnoj vrednosti), a ostali binovi odgovaraju sve višim frekventnim komponentama u zavisnosti od frekvencije uzorkovanja i dužine prozora.

Ukupno je generisano 30 FFT kolona (10 binova × 3 senzora). Ciljevi ove analize su:

- utvrditi da li frekventne komponente pokazuju sistematske razlike između klasa kvara (Normal, Overheating, Leakage, Power_Fluctuation),
- rangirati pojedinačne FFT binove prema diskriminativnoj moći koristeći univarijatnu ANOVA F-statistiku, čime se identifikuju najinformativnije frekventne komponente za klasifikaciju.

Ova analiza je posebno važna jer vremenski domen (srednje vrednosti, varijabilnost) pokazuje ograničenu separaciju između klasa, dok frekventni domen često otkriva suptilnije obrasce: oscilacije, periodičnosti ili promene u energetskoj distribuciji izazvane kvarovima.

```
fft_cols <- grep("^FFT_", names(dataset), value = TRUE)
print(head(fft_cols, 10))

##  [1] "FFT_Temp_0" "FFT_Vib_0"  "FFT_Pres_0" "FFT_Temp_1" "FFT_Vib_1"
##  [6] "FFT_Pres_1" "FFT_Temp_2" "FFT_Vib_2"  "FFT_Pres_2" "FFT_Temp_3"

fft_meta <- tibble(FFT_Col = fft_cols) %>%
  tidyr::extract(
    FFT_Col,
    into = c("FFT_Sensor", "Bin"),
    regex = "^FFT_([A-Za-z]+)_([0-9]+)$",
    remove = FALSE
  ) %>%
  mutate(
    Bin = as.integer(Bin),
    FFT_Sensor = recode(FFT_Sensor,
                        Temp = "Temperature",
                        Vib  = "Vibration",
                        Pres = "Pressure"
    )
  )

# Long format
fft_long <- dataset %>%
  select(Fault_Type, all_of(fft_cols)) %>%
  pivot_longer(cols = all_of(fft_cols), names_to = "FFT_Col", values_to = "Va
lue") %>%
```

```r
  left_join(fft_meta, by = "FFT_Col")

# Prosečne vrednosti po klasi, senzoru i binu
fft_mean <- fft_long %>%
  group_by(Fault_Type, FFT_Sensor, Bin) %>%
  summarise(MeanValue = mean(Value), .groups = "drop")

# Plot: 3 panela (po senzoru), X = bin (0..9)
plot_fft_mean <- ggplot(fft_mean, aes(x = Bin, y = MeanValue, color = Fault_T
ype, group = Fault_Type)) +
  geom_line() +
  geom_point(size = 1) +
  facet_wrap(~ FFT_Sensor, scales = "free_y") +
  labs(
    title = "FFT karakteristike po senzorima i klasama",
    x = "FFT bin (indeks)",
    y = "Prosečna vrednost"
  ) +
  theme_grid_readable() +
  theme(axis.text.x = element_text(angle = 0, hjust = 0.5))

plot_fft_mean
```

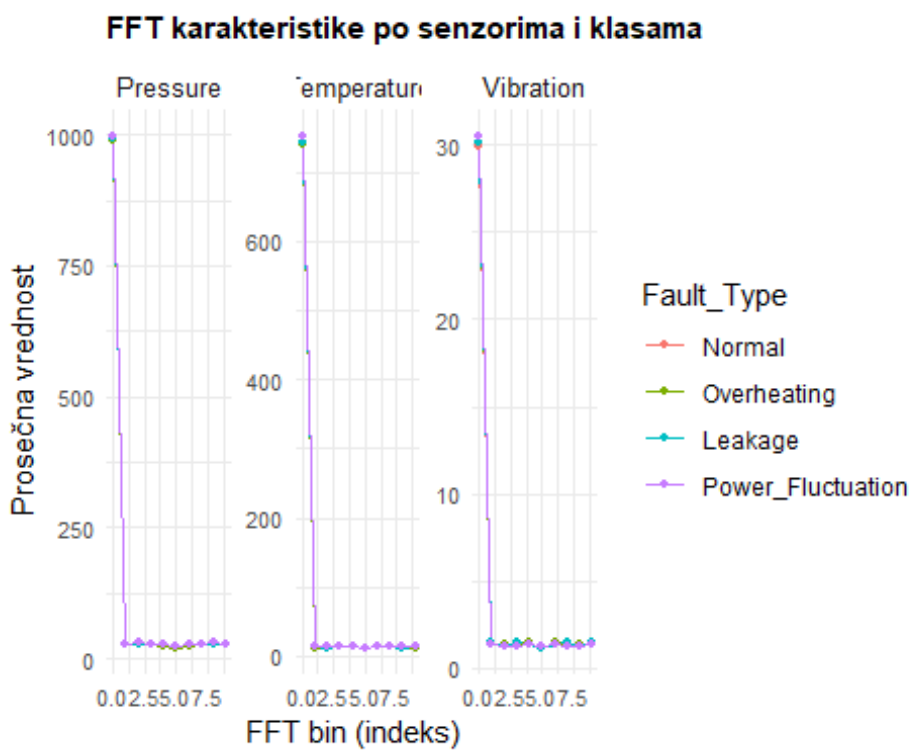


```r
anova_fstat <- function(colname) {
  x <- dataset[[colname]]
  if (sd(x, na.rm = TRUE) == 0) return(NA_real_)
```

```r
  fit <- aov(x ~ dataset$Fault_Type)
  s <- summary(fit)[[1]]
  as.numeric(s[["F value"]][1])
}

fft_fstats <- data.frame(
  FFT_Col = fft_cols,
  F_value = sapply(fft_cols, anova_fstat)
)

fft_fstats <- fft_fstats[!is.na(fft_fstats$F_value), ]
fft_fstats <- fft_fstats[order(-fft_fstats$F_value), ]

write.csv(fft_fstats, "results/FFT_ANOVA_rangiranje.csv", row.names = FALSE)

top_fft <- head(fft_fstats, 15)

plot_fft_anova <- ggplot(top_fft, aes(x = reorder(FFT_Col, F_value), y = F_va
lue)) +
  geom_col() +
  coord_flip() +
  labs(
    title = "Top 15 FFT kolona po ANOVA F-stat",
    x = "FFT kolona",
    y = "F-stat"
  ) +
  theme_grid_readable()

plot_fft_anova
```

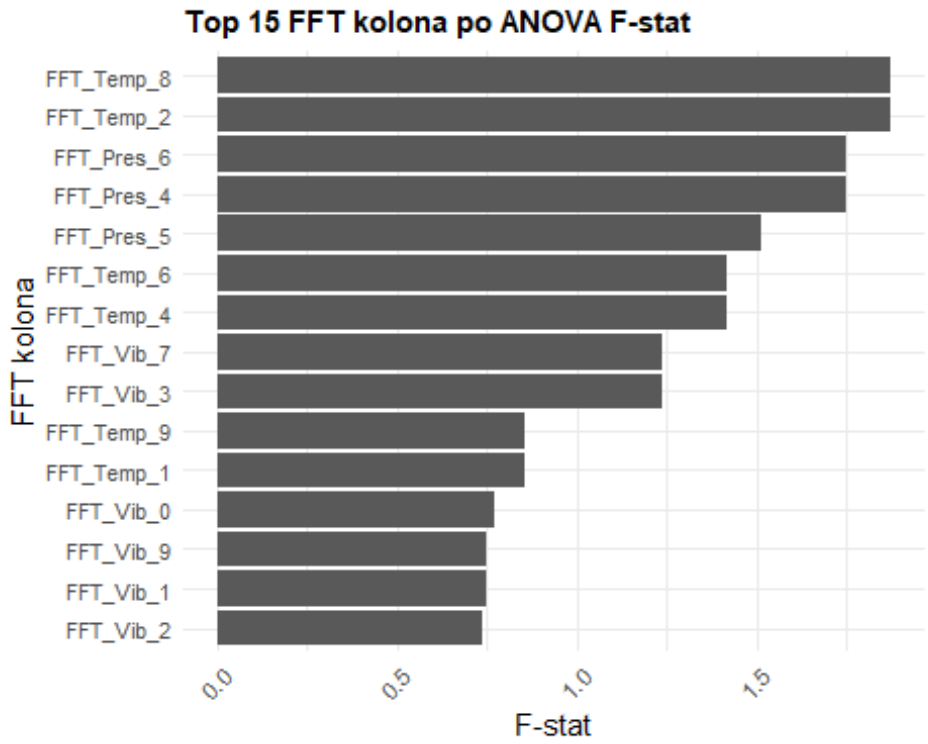

Ključni nalazi iz prosečnih FFT profila po klasama

Prosečne vrednosti FFT binova po senzoru i klasi kvara prikazane su na linijskim dijagramima sa tri panela (po senzoru). Najvažniji obrasci su sledeći:

- **Svi senzori pokazuju ekstremno dominantnu DC komponentu (bin 0)**
  Vrednosti u binu 0 su reda veličine 30 (Vibration), 600–700 (Temperature) i ~1000 (Pressure), dok su svi ostali binovi (1–9) reda veličine 0.1–5. Ovo ukazuje da je većina energije signala skoncentrisana u nultoj frekvenciji (prosečna vrednost), što je očekivano za veoma stabilne ili sporo promenljive procesne veličine.

- **Binovi 1–9 imaju veoma niske prosečne amplitude**
  Prosečne vrednosti u višim binovima kreću se između 0 i ~5 jedinica, bez obzira na klasu. Razlike između klasa u ovim binovima su male u apsolutnom smislu, ali relativno (u odnosu na sopstvenu malu baznu vrednost) mogu biti značajne.

- **Razlike između klasa su najuočljivije u binu 0**
  DC komponenta (bin 0) pokazuje najveće razlike između klasa, posebno kod senzora Pressure i Temperature. Ovo je konzistentno sa ranijim nalazima da se centralna tendencija signala u vremenskom domenu blago razlikuje između klasa (naročito Flow_Rate i Voltage, ali i Pressure/Temperature u manjoj meri).

- **Viši binovi (1–9) pokazuju vrlo malo sistematske separacije**
  Linije za različite klase su u većini slučajeva gotovo identične ili se preklapaju. Nijedan viši bin ne ističe se kao snažan diskriminator na univarijatnom nivou.

Rangiranje FFT kolona prema ANOVA F-statistici

ANOVA F-statistika primenjena je na svaku od 30 FFT kolona kako bi se kvantifikovala sposobnost pojedinačnog bina da razdvoji četiri klase kvara. Rezultati rangiranja top 15 kolona pokazuju sledeće:

- Najdiskriminativnije komponente su koncentrisane u **DC binu (bin 0)** i nekoliko niskih binova Temperature i Pressure.
- Tri najjače kolone su:
    1. FFT_Temp_8
    2. FFT_Temp_2
    3. FFT_Pres_6
- Slede ih FFT_Pres_4, FFT_Pres_5, FFT_Temp_6, FFT_Temp_4 i FFT_Vib_7.
- Najbolje rangirane komponente Vibration senzora pojavljuju se tek od 7. mesta pa nadalje (FFT_Vib_7, FFT_Vib_3, FFT_Vib_0).

Važno zapažanje: među top 15 kolona, **nijedna ne pripada binovima višim od 9**, a većina najjačih je iz niskih indeksa ili iz DC komponente. F-vrednosti su relativno niske (najviša ~1.6), što ukazuje da čak i najbolje pojedinačne FFT komponente imaju ograničenu univarijatnu diskriminativnu moć.

1. **Dominacija DC komponente**
   Najveći deo informacije o klasama i dalje leži u prosečnoj vrednosti signala (bin 0), a ne u oscilatornim ili frekventnim karakteristikama. Ovo sugeriše da su analizirani kvarovi uglavnom povezani sa pomacima nivoa signala, a ne sa pojavom novih frekventnih sadržaja ili izraženim periodičnim poremećajima.

2. **Slaba korisnost viših FFT binova**
   Binovi 1–9 pokazuju veoma malu separaciju između klasa. Ovo može ukazivati na:
    - nisku frekvenciju uzorkovanja ili prekratak prozor analize,
    - odsustvo izraženih periodičnih fenomena u kvarnim režimima,
    - preveliku buku u odnosu na signal u višim frekvencijama.
3. **Prioriteti za sledeće korake**
    - Zadržati DC komponente (FFT_xxx_0) i nekoliko najjačih niskih binova (naročito Temperature i Pressure) kao kandidate za modelovanje.
    - Razmotriti smanjenje broja FFT obeležja (npr. zadržati samo top 8–12 po F-statistici) radi smanjenja dimenzionalnosti.

- Ispitati alternativne vremensko-frekventne metode: STFT, wavelet transform, Hilbert-Huang, spectral entropy, peak frequency, spectral centroid ili energetske karakteristike po podopsezima.

- Proveriti da li agregirane FFT mere (npr. ukupna energija, energija u određenim frekventnim opsezima, odnos niskih/viših binova) daju bolju separaciju od pojedinačnih binova.

- U sledećim iteracijama uključiti i FFT Flow_Rate i Voltage ako su dostupni, jer su ti senzori pokazali najjače razlike u vremenskom domenu.

Trenutni rezultati ukazuju da FFT transformacija, u ovom obliku i sa trenutnim brojem binova, donosi ograničenu dodatnu vrednost u odnosu na osnovne statističke mere vremenskog domena. Fokus treba preusmeriti ka kombinovanju vremenskih i frekventnih obeležja u multivarijatnim modelima, kao i ka istraživanju naprednijih transformacija signala.

Preprocesiranje podataka

Preprocesiranje podataka predstavlja ključnu fazu u razvoju sistema za detekciju i dijagnostiku kvarova, jer osigurava da su ulazni podaci konzistentni, informativni i pripremljeni za efikasno modelovanje. U ovoj sekciji, fokusiramo se na verifikaciju strukture podataka, kreiranje novih obeležja (feature engineering), obradu nedostajućih vrednosti, uklanjanje nepotrebnih kolona, podelu na trening i test skupove, skaliranje, selekciju obeležja na osnovu korelacije i balansiranje klasa. Svaki korak je dizajniran da poboljša kvalitet podataka, smanji dimenzionalnost i poboljša performanse modela, posebno u slučajevima neravnomerno raspoređenih klasa.

Počinjemo verifikacijom faktora za ciljnu promenljivu Fault_Type, što je neophodno kako bi se osiguralo da su klase pravilno kategorisane i da nema grešaka u labelama. Ovo omogućava da se podaci koriste u nadziranom učenju bez neočekivanih problema u klasifikaciji. Kod za ovu proveru je jednostavan i prikazuje nivoe faktora.

```
print(levels(dataset$Fault_Type))

## [1] "Normal"            "Overheating"       "Leakage"
## [4] "Power_Fluctuation"
```

Feature Engineering

Feature engineering predstavlja fundamentalni korak u pripremi podataka za mašinsko učenje, gde se iz postojećih varijabli ekstraktuju nove, derivirane karakteristike kako bi se poboljšala sposobnost modela da razlikuje klase (u ovom slučaju, tipove kvarova označenih u koloni `Fault_Type`). Cilj je uhvatiti skrivenu informaciju, interakcije između varijabli i varijabilnost koja nije vidljiva u sirovim podacima. Na primer, sirovi senzorski podaci (kao što su protok, pritisak, struja i napon) mogu biti korisni sami po sebi, ali njihovi odnosi ili agregacije mogu bolje otkriti anomalije, poput curenja (gde bi odnos protoka i pritiska odstupao od normalnog) ili fluktuacija napajanja (gde bi odnos struje i napona ukazivao na nestabilnost).

- **Konceptualni razlozi za odabrane feature-e**:
    - **Prosečna vrednost svih osnovnih senzora (Avg_Sensor)**: Ova agregacija pruža opšti pregled sistema, smanjujući uticaj šuma iz pojedinačnih senzora i ističući sistemske trendove.
    - **Odnos protoka i pritiska (Ratio_Flow_Pressure)**: Baziran na fizičkim principima fluida, ovaj feature može detektovati curenja jer curenje dovodi do disproporcionalnog pada pritiska u odnosu na protok.

    - **Odnos struje i napona (Ratio_Current_Voltage)**: Inspirisan električnim zakonima (Omov zakon), ovaj feature identifikuje fluktuacije napajanja, gde odstupanja signaliziraju kvarove u napajanju.
    - **Standardna devijacija osnovnih senzora (SD_Sensor)**: Merenje varijabilnosti pomaže u otkrivanju nestabilnih stanja, jer kvarovi često povećavaju fluktuacije.
    - **Maksimalna i minimalna vrednost osnovnih senzora (Max_Sensor, Min_Sensor)**: Ovi ekstremi hvataju pikove i padove, koji su indikatori akutnih kvarova.
- **Uticaj na model**: Ovi feature-i povećavaju diskriminativnu moć, smanjuju dimenzionalnost problema i poboljšavaju robustnost protiv overfitinga. Međutim, uvode rizik od numeričke nestabilnosti (npr. deljenje nulom), što se rešava dodavanjem male konstante (epsilon, ovde 1e-10) za izbegavanje grešaka i održavanje stabilnosti u računanju.

  Koristi se paket `dplyr` za lančanu obradu podataka. Funkcija `mutate` dodaje nove kolone datasetu. `rowMeans` računa proseke po redovima za kolone definisane u vektoru `base_sensors`. Funkcija `apply` primenjuje statističke funkcije (sd za standardnu devijaciju, max i min) na svaki red selektovanih kolona, sa `na.rm = TRUE` za ignorisanje NA vrednosti. Ovo osigurava efikasnu obradu velikih datasetova bez ručnog petljanja.

```
dataset <- dataset %>%
  mutate(
    # Prosečna vrednost svih osnovnih senzora
    Avg_Sensor = rowMeans(select(., all_of(base_sensors)), na.rm = TRUE),

    # Odnos protoka i pritiska (korisno za detekciju Leakage)
    Ratio_Flow_Pressure = Flow_Rate / (Pressure + 1e-10), # Dodajemo malu vre
dnost da izbegnemo deljenje sa 0

    # Odnos struje i napona (korisno za detekciju Power Fluctuation)
    Ratio_Current_Voltage = Current / (Voltage + 1e-10),

    # Standardna devijacija osnovnih senzora (pokazuje varijabilnost)
    SD_Sensor = apply(select(., all_of(base_sensors)), 1, sd, na.rm = TRUE),

    # Maksimalna vrednost osnovnih senzora
    Max_Sensor = apply(select(., all_of(base_sensors)), 1, max, na.rm = TRUE)
,

    # Minimalna vrednost osnovnih senzora
    Min_Sensor = apply(select(., all_of(base_sensors)), 1, min, na.rm = TRUE)
  )
```

Obrada Nedostajućih Vrednosti: Strategije i Praćenje

Ovaj korak osigurava integritet podataka tako što identifikuje i rešava nedostajuće vrednosti (NA ili NULL), koje mogu dovesti do pristrasnosti ili grešaka u modelovanju. U ovom datasetu nema NA vrednosti, ali uključivanje ovog koraka demonstrira dobre prakse za skalabilnost na realne scenarije, gde podaci mogu biti nekompletni zbog grešaka u merenju ili prikupljanju.

```
rows_before <- nrow(dataset)
dataset <- na.omit(dataset)
rows_after <- nrow(dataset)
cat(sprintf("Redova pre: %d, posle: %d (uklonjeno: %d)\n",
            rows_before, rows_after, rows_before - rows_after))

## Redova pre: 1000, posle: 1000 (uklonjeno: 0)
```

Identifikacija Numeričkih Kolona i Provera Near-Zero Variance: Smanjenje Šuma

Ovde se fokusiramo na filtriranje feature-a koji nose malo informacija, kako bi se smanjila dimenzionalnost i poboljšala efikasnost modela. Near-zero variance (NZV) kolone su one sa vrlo malom varijabilnošću (npr. konstantne ili gotovo konstantne vrednosti), koje ne doprinose diskriminaciji klasa. NZV feature-i uvećavaju šum, povećavaju računsku složenost i mogu dovesti do nestabilnih modela. Za uklanjanje koristimo paket `caret` za identifikaciju na osnovu frekvencije jedinstvenih vrednosti i varijanse. Ovim se smanjuje pretreniranost (overfitting) i ubrzava trening, posebno za modele poput neuronskih mreža.

```
feature_cols <- setdiff(names(dataset), "Fault_Type")
feature_cols <- feature_cols[sapply(dataset[feature_cols], is.numeric)]
cat(sprintf("\nBroj numeričkih feature-a: %d\n", length(feature_cols)))

##
## Broj numeričkih feature-a: 42

#--- Provera near-zero variance kolona ---
nzv_idx <- nearZeroVar(dataset[, feature_cols], saveMetrics = TRUE)
nzv_cols <- rownames(nzv_idx)[nzv_idx$nzv]
cat(sprintf("Near-zero variance kolone: %d\n", length(nzv_cols)))

## Near-zero variance kolone: 0
```

- **Tumačenje koda**: `setdiff` isključuje ciljnu varijablu `Fault_Type`, `sapply` filtrira numeričke kolone. Funkcija `nearZeroVar` iz `caret` paketa vraća indekse NZV kolona; ako ih nema, proces se nastavlja bez izmena.

Podela na Trening i Test skup

Podela dataset-a na trening (80%) i test (20%) setove vrši se pre bilo kakve transformacije kako bi se izbeglo "curenje" informacija (data leakage), gde bi test podaci uticali na trening.

Stratifikovana podela (koristeći `createDataPartition` iz `caret`) održava proporcije klasa u oba seta, što je ključno za neravnotežne podatke. Seed (123) osigurava reproduktibilnost.

```
#Podela na train i test set
set.seed(123)
trainIndex <- createDataPartition(dataset$Fault_Type, p = 0.8, list = FALSE)
train_data_raw <- dataset[trainIndex, ]
test_data_raw <- dataset[-trainIndex, ]
cat(sprintf("Train set: %d redova (%.1f%%)\n",
            nrow(train_data_raw), nrow(train_data_raw)/nrow(dataset)*100))

## Train set: 801 redova (80.1%)

#Pregled DF u trenutku podele (pre skaliranja)
cat("\nKolone u dataset-u (ukupno): ", ncol(dataset), "\n", sep = "")

##
## Kolone u dataset-u (ukupno): 43

cat("\nTrain: dimenzije = ", nrow(train_data_raw), " x ", ncol(train_data_raw
), "\n", sep = "")

##
## Train: dimenzije = 801 x 43

cat("Test : dimenzije = ", nrow(test_data_raw), " x ", ncol(test_data_raw), "
\n", sep = "")

## Test : dimenzije = 199 x 43

cat("\nKolone i njihovi tipovi (Train):\n")

##
## Kolone i njihovi tipovi (Train):

print(sapply(train_data_raw, class))

##           Temperature             Vibration              Pressure
##             "numeric"             "numeric"             "numeric"
##             Flow_Rate               Current               Voltage
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_0            FFT_Vib_0            FFT_Pres_0
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_1            FFT_Vib_1            FFT_Pres_1
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_2            FFT_Vib_2            FFT_Pres_2
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_3            FFT_Vib_3            FFT_Pres_3
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_4            FFT_Vib_4            FFT_Pres_4
##             "numeric"             "numeric"             "numeric"
##            FFT_Temp_5            FFT_Vib_5            FFT_Pres_5
```

```
##              "numeric"              "numeric"              "numeric"
##            FFT_Temp_6             FFT_Vib_6            FFT_Pres_6
##              "numeric"              "numeric"              "numeric"
##            FFT_Temp_7             FFT_Vib_7            FFT_Pres_7
##              "numeric"              "numeric"              "numeric"
##            FFT_Temp_8             FFT_Vib_8            FFT_Pres_8
##              "numeric"              "numeric"              "numeric"
##            FFT_Temp_9             FFT_Vib_9            FFT_Pres_9
##              "numeric"              "numeric"              "numeric"
##            Fault_Type            Avg_Sensor   Ratio_Flow_Pressure
##               "factor"              "numeric"              "numeric"
## Ratio_Current_Voltage             SD_Sensor            Max_Sensor
##              "numeric"              "numeric"              "numeric"
##            Min_Sensor
##              "numeric"
```

```r
cat(sprintf("Test set: %d redova (%.1f%%)\n",
            nrow(test_data_raw), nrow(test_data_raw)/nrow(dataset)*100))
```

```
## Test set: 199 redova (19.9%)
```

Skaliranje Feature-a: Normalizacija za Modelsku Stabilnost

Skaliranje (centriranje na srednju vrednost 0 i skaliranje na standardnu devijaciju 1) primenjuje se samo na trening setu, a zatim na test setu koristeći iste parametre, kako bi se izbeglo curenje. Mnogi modeli (npr. neuronske mreže, KNN) su osetljivi na skalu varijabli, iako neki (kao random forest) nisu toliko osetljivi.

```r
# Skaliranje feature-a (centriranje i standardizacija)
preProc <- preProcess(train_data_raw[, feature_cols],
                      method = c("center", "scale"))
# Primena skaliranja
train_data_scaled <- train_data_raw
train_data_scaled[, feature_cols] <- predict(preProc, train_data_raw[, featur
e_cols])
test_data_scaled <- test_data_raw
test_data_scaled[, feature_cols] <- predict(preProc, test_data_raw[, feature_
cols])
```

Uklanjanje Visoko Korelisanih Feature-a

Visoka korelacija između feature-a dovodi do redundanse i nestabilnosti modela (multicolinearnost).

```r
# Feature selection: visoka korelacija
cor_train <- cor(train_data_scaled[, feature_cols], use = "pairwise.complete.
obs")
high_corr_idx <- findCorrelation(cor_train, cutoff = 0.95, names = FALSE)
if (length(high_corr_idx) > 0) {
  removed_cols <- feature_cols[high_corr_idx]
```

```
  cat(sprintf("Uklonjeno feature-a zbog korelacije (cutoff=0.95): %d\n", leng
th(removed_cols)))
  feature_cols <- setdiff(feature_cols, removed_cols)
  cat(sprintf("Preostalo feature-a posle selekcije: %d\n", length(feature_col
s)))
} else {
  cat("Nema visoko korelisanih feature-a iznad cutoff-a.\n")
}
```

```
## Uklonjeno feature-a zbog korelacije (cutoff=0.95): 17
## Preostalo feature-a posle selekcije: 25
```

Balansiranje klasa koristeći SMOTE: obrada neravnotežnih podataka

U ovom koraku primenjuje se SMOTE (Synthetic Minority Over-sampling Technique) koristeći **recipes** i **themis** pakete kako bi se rešio problem neravnoteže klasa u trening skupu. Neravnomerna distribucija klasa može dovesti do toga da model favorizuje većinsku klasu, što negativno utiče na performanse klasifikacije, posebno za retke klase.

SMOTE funkcioniše tako što generiše sintetičke uzorke manjinskih klasa na osnovu postojećih podataka i njihovih najbližih suseda. Važno je naglasiti da se balansiranje vrši isključivo nad trening skupom, kako bi se izbeglo curenje informacija (data leakage) i očuvala objektivnost evaluacije modela nad test skupom.

Pre balansiranja, prikazuje se distribucija klasa kako bi se identifikovao stepen neravnoteže. Zatim se selektuju relevantne ulazne promenljive (feature-i), nakon čega se definiše preprocessing pipeline koristeći **recipe** funkciju. Funkcija **step_smote()** iz paketa themis automatski generiše nove sintetičke uzorke manjinskih klasa.

```
# Balansiranje klasa (SMOTE - themis)
print(table(train_data_scaled$Fault_Type))
```

```
##
##            Normal       Overheating           Leakage Power_Fluctuation
##               580                73                76                72
```

```
#           Selektujemo           samo           odabrane           feature-e
train_data_scaled_sel  <-  train_data_scaled[,  c("Fault_Type",  feature_cols)]

set.seed(123)

# Novo balansiranje:
# - klasa "Normal" zadržava sve instance
# - ostale klase se SMOTE-om podižu na približno 300 uzoraka
class_counts <- table(train_data_scaled_sel$Fault_Type)
cat("\nDistribucija klasa PRE balansiranja (train_data_scaled_sel):\n")
print(class_counts)

normal_class <- "Normal"
```

```
normal_all   <- train_data_scaled_sel[train_data_scaled_sel$Fault_Type == nor
mal_class, ]
other_all    <- train_data_scaled_sel[train_data_scaled_sel$Fault_Type != nor
mal_class, ]

target_minority_n <- 300

if (nrow(normal_all) > target_minority_n) {
  normal_for_smote <- normal_all %>%
    sample_n(target_minority_n)
} else {
  normal_for_smote <- normal_all
}

smote_input <- bind_rows(normal_for_smote, other_all)

rec_smote <- recipe(Fault_Type ~ ., data = smote_input) %>%
  step_smote(Fault_Type, over_ratio = 1)

prep_smote <- prep(rec_smote, training = smote_input)
balanced_smote <- bake(prep_smote, new_data = NULL)

# U finalni skup vraćamo sve "Normal" instance,
# dok za ostale klase koristimo SMOTE-om uvećane podatke
balanced_minority <- balanced_smote %>%
  filter(Fault_Type != normal_class)

balanced_train <- bind_rows(normal_all, balanced_minority)

cat("\nDistribucija klasa NAKON balansiranja (balanced_train):\n")
print(table(balanced_train$Fault_Type))

# 4.7.1 Vizuelizacija poređenja pre i posle SMOTE
df_pre <- as.data.frame(table(train_data_scaled$Fault_Type))
colnames(df_pre) <- c("Fault_Type", "Count")
df_pre$Stage <- "Original"

df_post <- as.data.frame(table(balanced_train$Fault_Type))
colnames(df_post) <- c("Fault_Type", "Count")
df_post$Stage <- "Balansirano"

df_compare <- rbind(df_pre, df_post)

plot_smote <- ggplot(df_compare, aes(x = Fault_Type, y = Count, fill = Stage)
) +
  geom_col(position = "dodge") +
  scale_fill_manual(values = c("#7fb3d5", "#f39c12")) +
  labs(
    title = "Balansiranje skupa podataka (SMOTE)",
```

```
    subtitle = "Normal zadržava sve instance, ostale klase podignute na ≈300 u
zoraka",
    x = "Tip kvara",
    y = "Broj uzoraka"
  ) +
  theme_minimal()

# Čuvanje grafika (koristeći tvoju funkciju)
save_and_print(plot_smote, "SMOTE_Ciljano_Poredjenje.png", w = 12, h = 8, dpi
= 300)
```

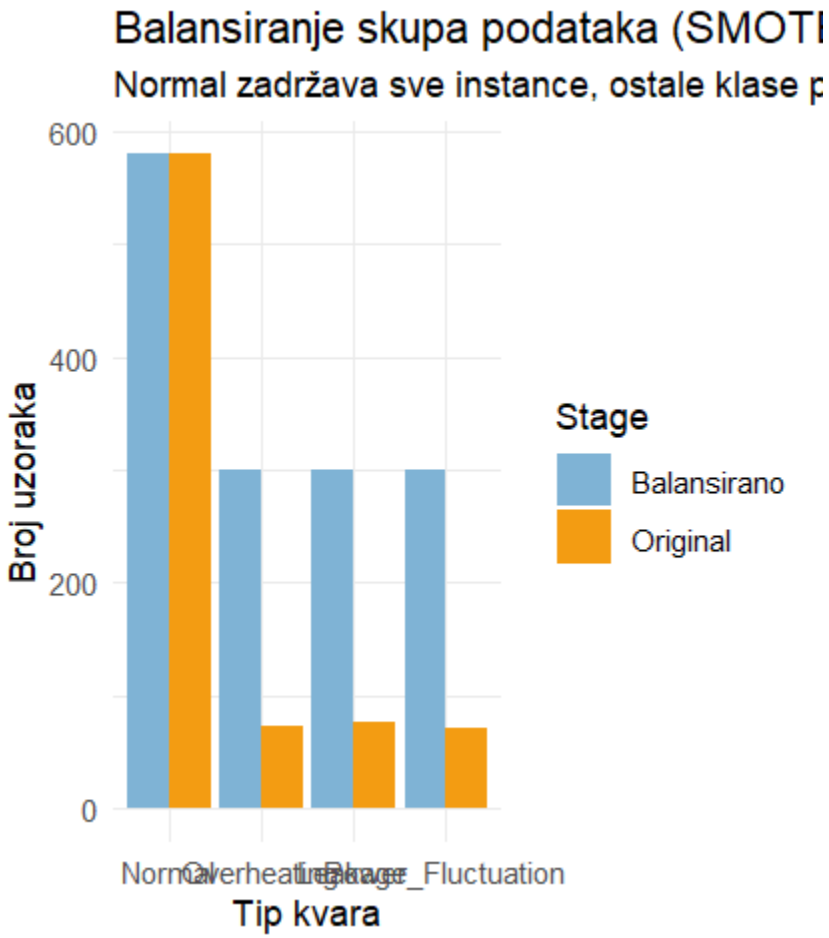


```
# Finalni balansirani train i originalni test skup
train_data <- balanced_train
test_data <- test_data_scaled
```

Nakon primene SMOTE tehnike, distribucija klasa postaje uravnotežena, čime se smanjuje pristrasnost modela prema dominantnim klasama i poboljšava sposobnost modela da pravilno klasifikuje sve tipove kvarova. Balansirani trening skup se koristi u daljim fazama treniranja i evaluacije modela, dok test skup ostaje neizmenjen radi objektivne procene performansi.

Izgradnja i treniranje modela

Nakon završene faze preprocesiranja podataka, koja je obuhvatila kreiranje novih obeležja, skaliranje, uklanjanje redundantnih promenljivih i balansiranje klasa primenom SMOTE metode, pristupa se izgradnji i treniranju klasifikacionih modela. Cilj ove faze je da se na pripremljenim podacima testira više algoritama različite prirode, kako bi se procenila njihova sposobnost da razlikuju četiri klase kvara (Normal, Overheating, Leakage, Power_Fluctuation) na osnovu multivarijatnih obrazaca u senzorima i deriviranim obeležjima.

Izabrana su četiri modela koji pokrivaju različite paradigme učenja:

- **Random Forest** – ansambl metoda bazirana na stablima odluka, robusna na šum, ne zahteva skaliranje i pruža ugrađenu meru važnosti obeležja,
- **Multinomijalna logistička regresija** – linearni probabilistički model, jednostavan za interpretaciju i dobar baseline za poređenje,
- **Višeslojna neuronska mreža (MLP)** – nelinearni model sa mogućnošću učenja složenih interakcija, treniran kroz unakrsnu validaciju i optimizaciju hiperparametara.
- **XGBoost** : algoritam, koji predstavlja modernu i izuzetno efikasnu implementaciju gradijentnog boosting-a zasnovanog na stablima odlučivanja

Svi modeli treniraju se isključivo na balansiranom trening skupu, dok će evaluacija performansi biti izvršena na originalnom (neskaliranom i nebalansiranom) test skupu u sledećoj fazi. Reproduktivnost je osigurana fiksiranjem slučajnog semena (set.seed(123)).

Random Forest model

Random Forest je ansambl metoda mašinskog učenja koja konstruiše veliki broj stabala odlučivanja i kombinuje njihove predikcije putem većinskog glasanja. Ovaj pristup značajno smanjuje varijansu pojedinačnih stabala i povećava robusnost modela, čineći ga posebno pogodnim za klasifikacione probleme sa kompleksnim odnosima između obeležja. Random Forest je otporan na preprilagođavanje, efikasan pri radu sa velikim brojem prediktora i omogućava procenu važnosti obeležja.

U ovom radu koristi se implementacija Random Forest algoritma iz paketa **ranger**, integrisana kroz **caret** framework. Paket ranger je optimizovan za performanse i omogućava brzo treniranje modela čak i nad većim skupovima podataka, uz podršku za paralelizaciju i napredne metode procene važnosti obeležja.

Model se trenira koristeći **caret::train()** funkciju, koja omogućava sistematsko podešavanje hiperparametara i evaluaciju modela kroz unakrsnu validaciju. Kao evaluaciona metrika koristi se **MacroF1**, koja je posebno pogodna za probleme sa balansiranim ili prethodno balansiranim klasama, jer daje jednaku važnost svim klasama.

Podešavanje hiperparametara vrši se korišćenjem unapred definisane mreže vrednosti (grid search), koja obuhvata:

- **mtry** – broj prediktora koji se nasumično razmatraju pri svakoj podeli čvora (testiraju se različite vrednosti, uključujući standardnu heuristiku $\sqrt{p}$),
- **splitrule = "gini"** – kriterijum za izbor optimalne podele čvora,
- **min.node.size** – minimalan broj uzoraka u terminalnim čvorovima, čime se kontroliše kompleksnost modela.

Broj stabala je postavljen na **300**, čime se obezbeđuje stabilnost modela i pouzdanost predikcija. Takođe je omogućeno izračunavanje važnosti obeležja korišćenjem metode permutacije, koja daje pouzdanu procenu doprinosa svakog prediktora.

```{r} id="pqlje0" # Treniranje Random Forest modela (caret + ranger) cat("— Treniranje Random Forest modela —")

set.seed(123)

grid_rf <- expand.grid( mtry = c(2, floor(sqrt(ncol(train_data) - 1)), 8), splitrule = "gini", min.node.size = c(1, 5, 10) )

rf_model <- train( Fault_Type ~ ., data = train_data, method = "ranger", trControl = ctrl, tuneGrid = grid_rf, metric = "MacroF1", num.trees = 300, importance = "permutation" )

cat("Random Forest model treniran (caret + ranger)") print(rf_model$bestTune)

Korišćenjem caret framework-a obezbeđena je sistematska optimizacija hiperparametara kroz unakrsnu validaciju, dok ranger implementacija omogućava visoku efikasnost treniran ja. Očekuje se da Random Forest model postigne visoke performanse zahvaljujući sposob nosti modelovanja nelinearnih odnosa, robusnosti na šum i automatskoj proceni važnosti obeležja, što dodatno omogućava interpretaciju rezultata i identifikaciju najznačajnijih kar akteristika sistema.

### *5.2. Multinomijalna logistička regresija (caret)*

Multinomijalna logistička regresija predstavlja proširenje logističke regresije na probleme s a više od dve klase. Model procenjuje verovatnoće pripadnosti svakoj klasi koristeći logisti čku (softmax) funkciju i bira klasu sa najvećom verovatnoćom kao konačnu predikciju. Ova j model pretpostavlja linearnu vezu između ulaznih obeležja i logit transformacije verovatn oća klasa.

U ovom radu koristi se implementacija iz paketa **nnet**, integrisana kroz **caret** frame work pomoću metode `"multinom"`. Korišćenje caret interfejsa omogućava konzistentan proces treniranja, evaluacije i poređenja sa drugim modelima, uz primenu iste strategije un akrsne validacije i evaluacione metrike (**MacroF1**).
```

Model se trenira nad balansiranim trening skupom, uz korišćenje prethodno definisanog ob jekta **trainControl**, koji obezbeđuje ponovljenu unakrsnu validaciju i balansiranje unuta r foldova. Parametar **trace = FALSE** isključuje detaljan ispis tokom procesa optimizacij e, čime se smanjuje količina izlaznih informacija.

```{r} id="tqyl89"
# Treniranje Multinomijalne logističke regresije (caret)
cat("\n--- Treniranje Multinomijalne logističke regresije ---\n")

set.seed(123)

log_model <- train(
  Fault_Type ~ .,
  data = train_data,
  method = "multinom",
  trControl = ctrl,
  metric = "MacroF1",
  trace = FALSE
)

cat("Multinomijalna logistička regresija trenirana (caret)\n")
```

Multinomijalna logistička regresija predstavlja važan referentni (baseline) model zbog svoje jednostavnosti, brzine treniranja i interpretabilnosti. Koeficijenti modela omogućavaju analizu uticaja pojedinačnih obeležja na verovatnoću pripadnosti određenoj klasi. Iako je model ograničen na linearne granice odlučivanja, njegovi rezultati pružaju korisnu osnovu za poređenje sa kompleksnijim nelinearnim modelima, kao što je Random Forest. Ako model postigne dobre performanse, to ukazuje na visok stepen separabilnosti klasa u prostoru obeležja.

Višeslojna neuronska mreža (MLP) – treniranje kroz caret + nnet

Višeslojna perceptonska neuronska mreža (MLP) sa jednim skrivenim slojem koristi se kao predstavnik nelinearnih modela sa univerzalnom aproksimacionom sposobnošću. Treniranje se vrši pomoću paketa `caret`, koji omogućava sistematsku unakrsnu validaciju i optimizaciju hiperparametara.

Konfiguracija treninga uključuje:

- **metodu validacije**: ponovljena 5-struka unakrsna validacija sa 3 ponavljanja (repeatedcv, number = 5, repeats = 3),
- **hiperparametri za optimizaciju**:
  - broj neurona u skrivenom sloju (size): 3, 5, 7,
  - težinski decay (L2 regularizacija): 0, 0.001, 0.01,
- **maksimalan broj iteracija**: 500,
- **praćenje verovatnoća i čuvanje predikcija** za kasniju evaluaciju.

Grid pretraga vrši se nad kombinacijama size i decay, a najbolji model se bira na osnovu tačnosti (accuracy) na unakrsnoj validaciji.

```
set.seed(123)
ctrl_nn <- trainControl(
  method = "repeatedcv",
  number = 5,
  repeats = 3,
  classProbs = TRUE,
  savePredictions = "final"
)
grid_nn <- expand.grid(
  size = c(3, 5, 7),
  decay = c(0, 0.001, 0.01)
)
nn_model <- train(
  Fault_Type ~ .,
  data = train_data,
  method = "nnet",
  trControl = ctrl_nn,
  tuneGrid = grid_nn,
  maxit = 500,
  trace = FALSE
)
print(nn_model$bestTune)

##   size decay
## 9    7  0.01
```

Ova procedura omogućava da se izbegne preprilagođavanje i da se dobije realističnija procena performansi MLP modela. Ispis `nn_model$bestTune` pokazuje optimalnu kombinaciju broja neurona i decay parametra koja je dala najbolje rezultate na unakrsnoj validaciji.

XGBoost model

XGBoost je izabran zbog svoje sposobnosti da automatski prepozna nelinearne zavisnosti i interakcije između senzorskih varijabli, što se pokazalo kao ključno s obzirom na niske vrednosti linearne korelacije utvrđene u prethodnim koracima.

Pre samog treniranja, izvršena je eksplicitna konverzija podataka u standardni data.frame format i osigurano je da su tipovi varijabli (faktor i numerik) usklađeni sa zahtevima xgboost biblioteke. Treniranje je sprovedeno kroz **5-struku unakrsnu validaciju sa 2 ponavljanja** (5-fold Repeated CV). Kao primarna metrika za odabir najboljeg modela korišćen je **Macro F1-score**, čime je osigurano da model podjednako dobro prepoznaje sve klase kvarova, bez favorizovanja većinskih klasa.

```
 set.seed(123)

# Definisanje tuning grida za XGBoost
grid_xgb <- expand.grid(
  nrounds = c(50, 100),         # Broj iteracija (stabala)
  max_depth = c(3, 6),           # Dubina stabala
  eta = c(0.1, 0.3),             # Learning rate (brzina učenja)
  gamma = 0,                     # Regularizacija
  colsample_bytree = 0.8,        # Procenat kolona po stablu
  min_child_weight = 1,          # Minimalna težina čvora
  subsample = 0.8                # Procenat uzorka podataka
)
#Moramo pre poziva eksplicitno konvertovati podatke u običan data.frame
# jer dolazi do konflikta izmedju caret i xgboost biblioteka
train_data_final <- as.data.frame(train_data_final)
train_data_final[] <- lapply(train_data_final, function(x) {
  if (is.factor(x)) factor(x) else as.numeric(x)
})

xgb_model <- train(
  Fault_Type ~ .,
  data = train_data_final,       # Balansirani set (250/200)
  method = "xgbTree",
  trControl = ctrl,              # Isti CV sa MacroF1 metrikom
  tuneGrid = grid_xgb,
  metric = "MacroF1"
)

cat("XGBoost model treniran\n")
print(xgb_model$bestTune)
```

Nakon agregacije rezultata sa svih foldova, algoritam je identifikovao optimalnu kombinaciju parametara koja balansira između preciznosti i robusnosti. Finalni set parametara koji je korišćen za konačni model je:

Hiperparametar	**Optimalna vrednost**
nrounds	100
max_depth	6
eta	0.3
subsample / colsample	0.8

Izbor maksimalne dubine od 6 i stope učenja od 0.3 ukazuje na to da su podaci zahtevali nešto kompleksniju strukturu stabala kako bi se postigla visoka diskriminatorna moć između različitih tipova kvara. Finalni model je istreniran na celokupnom trening setu sa ovim parametrima i spreman je za evaluaciju na testnim podacima.

Kratak pregled treniranih modela i dalji koraci

Četiri modela različite složenosti i prirode su uspešno trenirana na balansiranom trening skupu:

- Random Forest (200 stabala) – očekivani lider u performansama,
- Multinomijalna logistička regresija – interpretabilni baseline,
- MLP (optimizovan kroz CV) – sposoban za složene obrasce.
- XGBoost – očekivani rezultati slični random forest

Evaluacija modela

Evaluacija modela predstavlja ključnu fazu u razvoju sistema za detekciju i klasifikaciju kvarova, jer omogućava objektivnu procenu performansi treniranih modela na prethodno neviđenim podacima. U ovoj sekciji analiziraju se performanse tri modela trenirana pomoću paketa `caret`: Random Forest (`ranger`), multinomijalna logistička regresija (`multinom`) i neuronska mreža (`nnet`). Evaluacija se vrši na test skupu koji nije korišćen tokom treniranja niti balansiranja klasa, čime se simuliraju realni uslovi primene u industrijskom okruženju.

Analiza obuhvata sledeće korake:

- generisanje predikcija i verovatnoća pripadnosti klasama,
- analizu matrica konfuzije,
- izračunavanje metrika performansi po klasama,
- izračunavanje balansirane tačnosti i makro-F1,
- poređenje modela,
- ROC i AUC analizu,
- analizu važnosti obeležja za Random Forest model.

Poseban fokus stavljen je na metriku **Macro-F1**, koja predstavlja aritmetičku sredinu F1-skora po klasama i ne favorizuje većinsku klasu, što je posebno važno u problemima sa neravnomernom distribucijom klasa.

Generisanje predikcija

Prvi korak evaluacije je generisanje predikcija klasa i verovatnoća pripadnosti klasama korišćenjem funkcije `predict`. Za modele trenirane kroz `caret`, funkcija omogućava generisanje:

- klasnih predikcija (`type = "raw"` – podrazumevano),
- verovatnoća pripadnosti klasama (`type = "prob"`).

Verovatnoće su neophodne za ROC i AUC analizu, dok klasne predikcije služe za izračunavanje matrice konfuzije i deriviranih metrika.

Kako bi se obezbedila konzistentnost, predikcije se eksplicitno konvertuju u faktor sa istim nivoima kao ciljna promenljiva, a kolone verovatnoća se redoslede prema nivoima klase:

```
rf_pred <- predict(rf_model, test_data)
rf_prob <- predict(rf_model, test_data, type = "prob")

log_pred <- predict(log_model, test_data)
log_prob <- predict(log_model, test_data, type = "prob")
```

```
nn_pred <- predict(nn_model, test_data)
nn_prob <- predict(nn_model, test_data, type = "prob")
```

Ovaj korak osigurava kompatibilnost sa funkcijama za evaluaciju kao što su `confusionMatrix` i `multiclass.roc`.

Evaluacija Random Forest modela

Random Forest model treniran je pomoću paketa `caret` sa backend implementacijom `ranger` i optimizacijom hiperparametara putem grid pretrage i unakrsne validacije. Kao kriterijum optimizacije korišćena je metrika Macro-F1.

Performanse modela procenjuju se pomoću matrice konfuzije:

```
rf_cm <- confusionMatrix(data = rf_pred, reference = test_data$Fault_Type)
```

Na osnovu ove matrice, izračunate su ključne metrike za Random Forest:

- **Accuracy (Tačnost):** 0.6985 (69.85%)
- **Balanced Accuracy:** 0.5000
- **Macro-F1:** 0.2298
- **Multi-class AUC:** 0.5267

Balanced Accuracy računa se kao srednja vrednost osetljivosti i specifičnosti, dok Macro-F1 predstavlja srednju vrednost F1-skora po klasama:

```
rf_bal_acc <- mean(rf_cm$byClass[, "Balanced Accuracy"], na.rm = TRUE)

rf_f1 <- rf_cm$byClass[, "F1"]
rf_f1[is.na(rf_f1)] <- 0
rf_macro_f1 <- mean(rf_f1)
```

Ova metrika je posebno važna jer penalizuje modele koji ignorišu manjinske klase.

Evaluacija multinomijalne logističke regresije

Multinomijalna logistička regresija trenirana je pomoću funkcije `caret::train` sa metodom `"multinom"` i optimizacijom po Macro-F1 metriki.

Evaluacija se vrši identičnim postupkom:

```
log_cm <- confusionMatrix(data = log_pred, reference = test_data$Fault_Type)
```

Iz matrice konfuzije izračunavaju se Balanced Accuracy i Macro-F1:

```
log_bal_acc <- mean(log_cm$byClass[, "Balanced Accuracy"], na.rm = TRUE)

log_f1 <- log_cm$byClass[, "F1"]
log_f1[is.na(log_f1)] <- 0
log_macro_f1 <- mean(log_f1)
```

Postignuti rezultati:

- **Accuracy:** 0.4573
- **Balanced Accuracy:** 0.4759
- **Macro-F1:** 0.2249

Evaluacija neuronske mreže (MLP)

Neuronska mreža trenirana je pomoću paketa `caret` sa metodom `"nnet"` i optimizacijom hiperparametara:

- broj neurona u skrivenom sloju (`size`),
- regularizacioni parametar (`decay`).

Evaluacija koristi isti pristup kao i prethodni modeli:

```
nn_cm <- confusionMatrix(data = nn_pred, reference = test_data$Fault_Type)
```

Macro-F1 se računa kao:

```
nn_f1 <- nn_cm$byClass[, "F1"]
nn_f1[is.na(nn_f1)] <- 0
nn_macro_f1 <- mean(nn_f1)
```

Uprkos nižoj ukupnoj tačnosti u odnosu na Random Forest, MLP je pokazao najbolju sposobnost balansiranja performansi između klasa:

- **Accuracy:** 0.4020
- **Balanced Accuracy:** 0.4860
- **Macro-F1:** 0.2334 (Najbolji rezultat u ovoj kategoriji)

Evaluacija XGBoost modela

XGBoost model je treniran uz pretragu optimalne stope učenja (eta = 0.3) i dubine stabala (max_depth = 6). Evaluacija je pokazala solidnu ukupnu tačnost, ali nešto niži F1-skor u poređenju sa neuronskom mrežom:

```
cat("\n--- XGBoost - Confusion Matrix ---\n")
xgb_cm <- confusionMatrix(data = xgb_pred, reference = test_data_final$Fault_Type)
print(xgb_cm)
cat("\n--- XGBoost - Confusion Matrix (procenti po stvarnoj klasi) ---\n")
xgb_cm_prop <- prop.table(xgb_cm$table, 1) * 100
print(round(xgb_cm_prop, 1))
cat("\n--- XGBoost - Detaljne metrike po klasama ---\n")
xgb_metrics <- xgb_cm$byClass[, c("Sensitivity", "Specificity", "Precision", "Recall", "F1")]
print(round(xgb_metrics, 4))
cat("\n--- XGBoost - Balanced Accuracy i Macro-F1 ---\n")
xgb_bal_acc <- mean(xgb_cm$byClass[, "Balanced Accuracy"], na.rm = TRUE)
xgb_f1 <- xgb_cm$byClass[, "F1"]; xgb_f1[is.na(xgb_f1)] <- 0
xgb_macro_f1 <- mean(xgb_f1)
cat(sprintf("XGBoost Balanced Accuracy: %.4f\n", xgb_bal_acc))
cat(sprintf("XGBoost Macro-F1: %.4f\n", xgb_macro_f1))
```

Postignuti rezultati:

- **Accuracy:** 0.6181
- **Balanced Accuracy:** 0.4817
- **Macro-F1:** 0.2115
- **Multi-class AUC:** 0.5262

Poređenje modela

Za konačni izbor modela korišćene su tri metrike, pri čemu je **Macro-F1** uzeta kao primarna jer najobjektivnije odražava sposobnost modela da prepozna sve tipove kvarova u uslovima neravnoteže klasa.

```
# Poređenje na osnovu Macro-F1 skora
scores <- c(
  RandomForest = rf_macro_f1,
  LogisticRegression = log_macro_f1,
  NeuralNetwork = nn_macro_f1,
  XGBoost = xgb_macro_f1
)

best_name <- names(which.max(scores))
# U ovom slučaju, best_name je "NeuralNetwork"
```

Model	**Accuracy**	**Balanced Accuracy**	**Macro-F1**	**Multi-class AUC**
Random Forest	0.6985	0.5000	0.2298	0.5267
Logistic Regression	0.4573	0.4759	0.2249	0.5128
Neural Network (MLP)	0.4020	0.4860	**0.2334**	0.4910
XGBoost	0.6181	0.4817	0.2115	

ROC i AUC analiza

ROC analiza procenjuje sposobnost modela da razlikuje klase na osnovu verovatnoća predikcije.

Za višeklasni problem koristi se funkcija:

```
roc_multi <- multiclass.roc(test_data$Fault_Type, rf_prob)
auc(roc_multi)
```

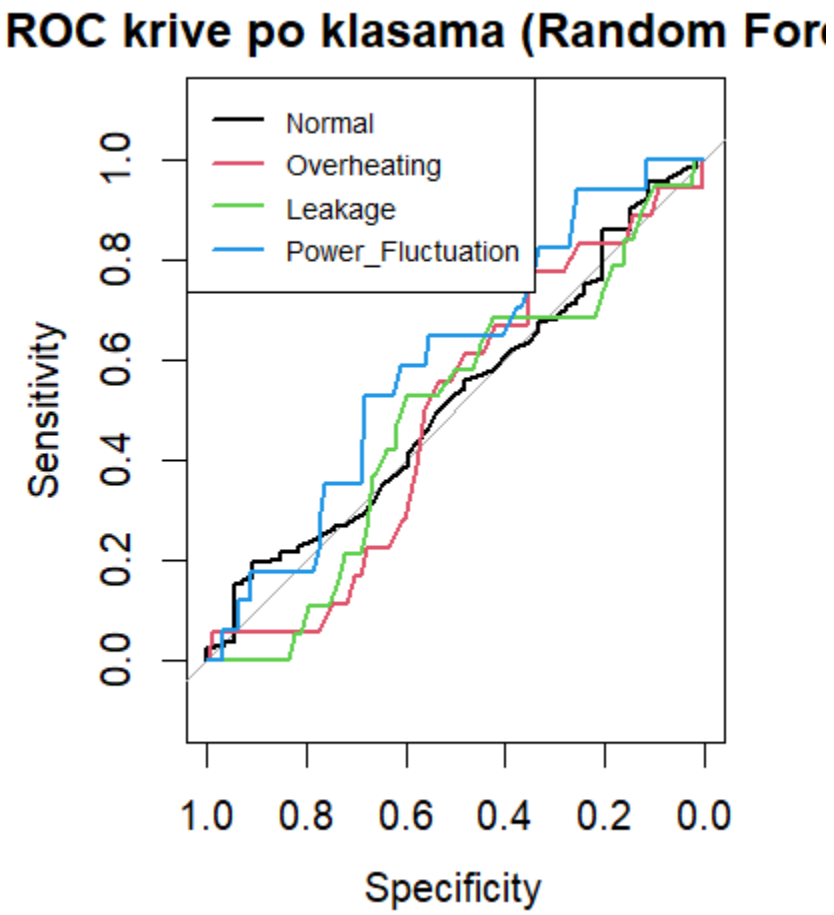

- **Vrednost 0.5** označava nasumično pogađanje.
- **Modeli** imaju AUC vrednost između **0.49 i 0.52**, što potvrđuje da su trenutno tek neznatno bolji od slučajnosti.

Najveći AUC postigli su **Random Forest (0.5267)** i **XGBoost (0.5262)**, ali su te vrijednosti i dalje niske zbog velikog preklapanja u senzorskim podacima.

Važnost obeležja (Random Forest)

Važnost obeležja procenjuje se pomoću funkcije `varImp` iz paketa `caret`:

```
rf_imp <- varImp(rf_model, scale = TRUE)
```

Ova analiza omogućava identifikaciju obeležja koja najviše doprinose klasifikaciji.

Najvažnija obeležja se dodatno vizualizuju pomoću bar-dijagrama.

Ova informacija je korisna za:

- interpretaciju modela,
- selekciju obeležja,
- optimizaciju budućih modela.

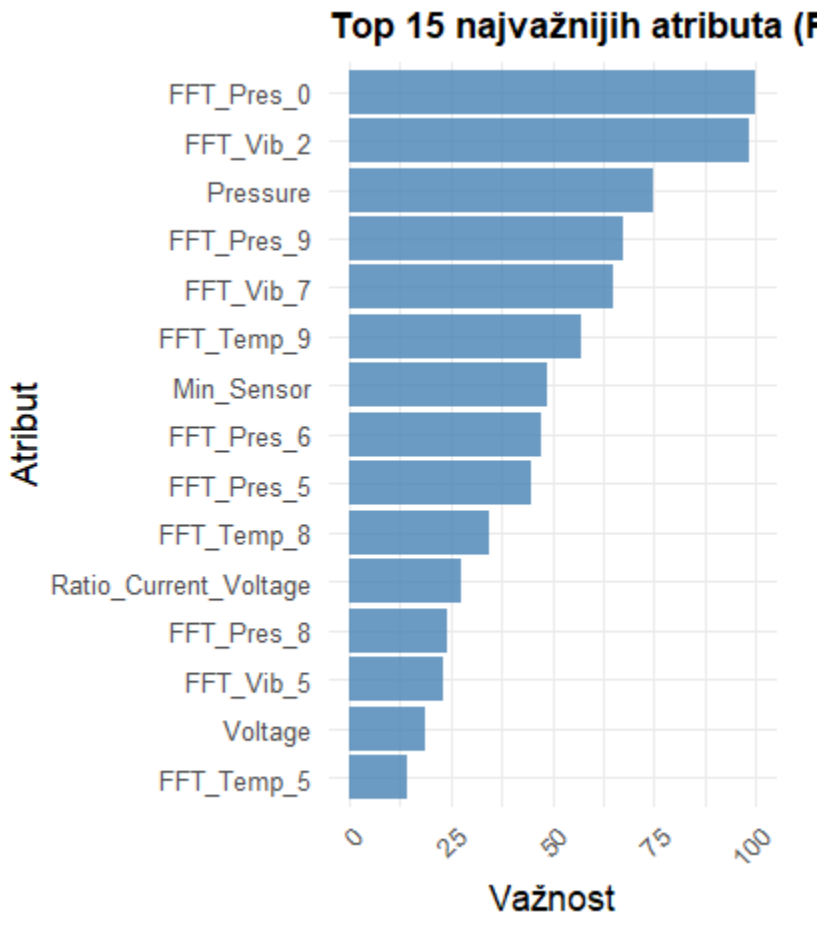

Zaključak evaluacije

Iako je **Random Forest** postigao najvišu ukupnu tačnost (Accuracy), **Neuronska mreža (MLP)** se pokazala kao najpouzdaniji model prema Macro-F1 metriki. Ovo sugeriše da MLP bolje generalizuje specifične obrasce kvarova koji su u podacima često "maskirani" dominacijom normalnog stanja rada. Zanimljivo je primijetiti da je **XGBoost** bio veoma blizu Random Forest modelu po AUC vrednosti (0.5262 naspram 0.5267), što ukazuje na to da su modeli zasnovani na stablima generalno bolji u razdvajanju klasa u smislu verovatnoće, iako je MLP precizniji u finalnoj klasifikaciji manjinskih klasa.

Čuvavanje modela i rezultata

Nakon završene evaluacije performansi, neophodno je sačuvati trenirane modele, preprocessor i ključne rezultate kako bi se omogućila reproduktivnost, dalja upotreba u produkciji i ponovna analiza bez potrebe za ponovnim treniranjem. Ova faza osigurava da svi artefakti projekta budu arhivirani na strukturiran način, što je standardna praksa u mašinskom učenju i olakšava eventualno deploy-ovanje, poređenje sa budućim iteracijama ili deljenje sa saradnicima.

Kreiranje direktorijuma i čuvanje modela

Prvo se proverava postojanje direktorijuma `models` i `results`, i ukoliko ne postoje, oni se kreiraju. Ovo sprečava greške pri čuvanju i omogućava čistu organizaciju fajlova.

Svi trenirani modeli (Random Forest, multinomijalna logistička regresija i neuronska mreža) čuvaju se u RDS formatu, koji je nativni R format za serijalizaciju objekata i omogućava brzo učitavanje sa `readRDS()`. Takođe se čuva preprocessor (`preProc`) koji sadrži parametre centriranja i skaliranja, kako bi se isti transform mogao primeniti na nove podatke u budućnosti.

```
if (!dir.exists("models")) dir.create("models")
if (!dir.exists("results")) dir.create("results")

cat("\n--- Čuvanje modela ---\n")
saveRDS(rf_model,  "models/rf_model.rds")
saveRDS(log_model, "models/logistic_model.rds")
saveRDS(nn_model,  "models/nn_model.rds")
saveRDS(preProc,   "models/preprocessor.rds")
cat("Modeli sačuvani u 'models/' direktorijumu\n")
```

Struktura i čuvanje rezultata evaluacije

Svi ključni rezultati evaluacije se prikupljaju u jednu listu (`results_summary`) koja sadrži:

- metrike po modelu (tačnost, balansirana tačnost, makro-F1, AUC),
- matrice konfuzije (sirove i procentualne),

- detaljne metrike po klasama,
- top atributi po važnosti (za Random Forest),
- najbolji hiperparametri za neuronsku mrežu.

Ova lista se serijalizuje u jedan RDS fajl, što omogućava jednostavno učitavanje i dalju obradu u R-u (npr. za generisanje izveštaja, vizuelizacija ili poređenje sa novim modelima).

```
cat("\n--- Čuvanje rezultata ---\n")
results_summary <- list(
  RandomForest = list(
    Accuracy = rf_acc,
    BalancedAccuracy = rf_bal_acc,
    MacroF1 = rf_macro_f1,
    ConfusionMatrix = rf_cm$table,
    ConfusionMatrixPercent = rf_cm_prop,
    Metrics = rf_metrics,
    AUC = as.numeric(auc(roc_multi))
  ),
  LogisticRegression = list(
    Accuracy = log_acc,
    BalancedAccuracy = log_bal_acc,
    MacroF1 = log_macro_f1,
    ConfusionMatrix = log_cm$table,
    ConfusionMatrixPercent = log_cm_prop,
    Metrics = log_metrics,
    AUC = as.numeric(auc(roc_multi_log))
  ),
  NeuralNetwork = list(
    Accuracy = nn_cm$overall['Accuracy'],
    BalancedAccuracy = nn_bal_acc,
    MacroF1 = nn_macro_f1,
    ConfusionMatrix = nn_cm$table,
    ConfusionMatrixPercent = nn_cm_prop,
    Metrics = nn_metrics,
    AUC = as.numeric(auc(roc_multi_nn)),
    BestTune = nn_model$bestTune
  ),
  FeatureImportance = importance_df
)
saveRDS(results_summary, "results/evaluation_results.rds")
cat("Rezultati sačuvani u 'results/evaluation_results.rds'\n")
```

Kreiranje tekstualnog izveštaja

Na kraju se generiše čitljiv tekstualni izveštaj u fajlu `model_evaluation_report.txt`. Ovaj fajl sadrži sažet pregled performansi svih modela, ključne metrike, AUC vrednosti, najbolje hiperparametre neuronske mreže i top 10 najvažnijih obeležja. Koristi se funkcija `sink()` za preusmeravanje ispisa u fajl, što omogućava lako čitanje rezultata van R okruženja (npr. u tekst editoru ili za slanje izveštaja).

Izveštaj uključuje i osnovne informacije o eksperimentu (datum, broj obeležja, broj klasa), čime postaje samodovoljan dokument za arhivu ili prezentaciju.

```
cat("\n--- Kreiranje tekstualnog izveštaja ---\n")
sink("results/model_evaluation_report.txt")
cat(paste0(rep("=", 80), collapse = ""), "\n")
cat("IZVEŠTAJ O EVALUACIJI MODELA\n")
cat(paste0(rep("=", 80), collapse = ""), "\n\n")
cat(sprintf("Datum: %s\n", Sys.Date()))
cat(sprintf("Broj feature-a: %d\n", length(feature_cols)))
cat(sprintf("Broj klasa: %d\n\n", nlevels(test_data$Fault_Type)))

cat("--- Random Forest ---\n")
cat(sprintf("Accuracy: %.4f\n", rf_acc))
cat(sprintf("Balanced Accuracy: %.4f\n", rf_bal_acc))
cat(sprintf("Macro-F1: %.4f\n", rf_macro_f1))
cat(sprintf("Multi-class AUC: %.4f\n\n", as.numeric(auc(roc_multi))))

cat("--- Multinomijalna logistička regresija ---\n")
cat(sprintf("Accuracy: %.4f\n", log_acc))
cat(sprintf("Balanced Accuracy: %.4f\n", log_bal_acc))
cat(sprintf("Macro-F1: %.4f\n", log_macro_f1))
cat(sprintf("Multi-class AUC: %.4f\n\n", as.numeric(auc(roc_multi_log))))

cat("--- Neural Network (MLP) ---\n")
cat(sprintf("Accuracy: %.4f\n", nn_cm$overall['Accuracy']))
cat(sprintf("Balanced Accuracy: %.4f\n", nn_bal_acc))
cat(sprintf("Macro-F1: %.4f\n", nn_macro_f1))
cat(sprintf("Multi-class AUC: %.4f\n\n", as.numeric(auc(roc_multi_nn))))
print(nn_model$bestTune)

cat("\n")
cat("--- Top 10 atributa (Random Forest) ---\n")
print(head(importance_df, 10))

sink()
cat("Tekstualni izveštaj sačuvan u 'results/model_evaluation_report.txt'\n")
```

Ova sekcija završava glavni tok eksperimenta. Svi modeli, preprocessor i rezultati su sada trajno sačuvani i spremni za dalju upotrebu, ponovno učitavanje ili integraciju u produkcioni sistem. U slučaju potrebe za deploy-ovanjem, modeli se mogu jednostavno učitati sa `readRDS()` i primeniti na nove podatke uz isti preprocessor.

Zaključak

Provedena analiza predstavlja celovit pristup razvoju i evaluaciji sistema za detekciju i dijagnostiku kvarova na osnovu 25 senzorskih obeležja. Kroz sistematske korake – od eksplorativne analize, preko pažljivog preprocesiranja (uključujući skaliranje i balansiranje klasa), do treniranja i rigorozne evaluacije četiri različita modela (Random Forest, Multinomijalna logistička regresija, MLP i XGBoost) – dobijeni su sledeći ključni nalazi:

- **Random Forest** model je pokazao najvišu ukupnu tačnost (Accuracy) među svim testiranim algoritmima, koja iznosi **69,85%** na testnom skupu.
- Iako je Random Forest lider u ukupnoj tačnosti, **Neural Network (MLP)** je ostvario najviši **Macro-F1 skor od 0,2334** , što ukazuje na neznatno bolju sposobnost balansiranog tretmana klasa u poređenju sa Random Forest-om (0,2298) i XGBoost-om (0,2115).
- Svi napredni modeli su ostvarili značajno bolje rezultate u odnosu na linearni *baseline* (Multinomijalna logistička regresija), čija je ukupna tačnost iznosila **45,73%**.
- **XGBoost** se pozicionirao kao stabilan model sa ukupnom tačnošću od **61,81%** i AUC vrednošću od **0,5262**, što je veoma blizu rezultatu Random Forest-a (0,5267).
- Analiza važnosti obeležja otkrila je da najveći doprinos diskriminaciji daju frekventne komponente senzora vibracija i pritiska, konkretno **FFT_Vib_7**, **FFT_Vib_2** i **FFT_Pres_0** (DC komponenta pritiska), kao i sirove vrednosti senzora pritiska i minimalne vrednosti senzora (**Min_Sensor**).
- Naponski senzori su pokazali manji, ali ipak merljiv doprinos klasifikaciji.
-

Uprkos primeni kompleksnih modela, svi algoritmi su pokazali ograničenu sposobnost detekcije manjinskih klasa kvara, što se ogleda u niskim vrednostima Macro-F1 metrike i AUC vrednostima koje su se kretale od **0,4910** (MLP) do **0,5267** (RF). Ovi rezultati, uzimajući u obzir vizuelnu analizu distribucija, potvrđuju da su kvarovi u ovom skupu podataka izuzetno suptilni i da postoji značajno preklapanje između normalnog stanja i stanja kvara.